

UAV辅助移动边缘计算中的长期动态激励与卸载优化

李锡泽

1 引言 (Introduction)

现有移动设备 (Mobile Device, MD) 受限于物理体积和本地算力, 难以满足 5G 场景下不断增长的计算需求。移动边缘计算 (Mobile Edge Computing, MEC) 通过将计算任务卸载至邻近边缘服务器, 为资源受限设备提供了有效支撑。在 UAV 辅助 MEC 网络中, 无人机可作为空中移动边缘服务器, 为地面基站覆盖不足区域的移动用户提供灵活的卸载服务。然而, 无人机需要承担飞行、通信和计算成本, 用户也具有追求自身效用最大化的自利性。因此, 有必要设计合理的激励机制, 以促进服务提供方与任务请求方持续参与计算卸载。

鉴于 UAV 与移动用户之间存在明显的层级决策关系, 现有研究常采用斯坦博格博弈刻画二者交互: 服务提供方作为领导者先行制定价格、资源分配或服务策略, 移动用户作为跟随者据此作出卸载决策。例如, Cheng 等通过刻画边缘服务器与移动用户之间的主从关系, 实现了边缘定价、资源分配和任务分配的联合优化 [1]。但这类方法通常以平台收益或服务提供方效用最大化为主要目标, 难以充分兼顾系统社会福利与交易公平性。

相比之下, 拍卖机制可将资源分配与支付规则纳入统一框架。Xiao 等结合双边拍卖和组合拍卖, 联合刻画多用户、多服务器间的双向竞价与多维资源分配 [2]; Li 等则针对任务价值随时间衰减的动态竞争场景, 提出 GMPO 机制, 通过短时限优化、单调赢家确定和临界价格支付提升总体效用并抑制虚假交易 [3]。相较于侧重供需撮合的双边拍卖, VCG 通过外部性定价, 在满足相应条件时可使个体申报与社会福利目标一致。在联邦学习场景中, Wu 等针对连续训练过程中的客户端参与问题, 提出长期自适应 VCG 拍卖机制, 将客户端选择与长期社会福利优化相结合 [4]。然而, 在边缘计算卸载的连续决策过程中, 当前时隙的申报可能影响后续资源分配; 该机制的定价主要依据当期即时福利, 对跨期外部性的显式刻画相对有限。

因此, 本文研究 UAV 辅助 MEC 网络中的长期动态激励与卸载优化问题, 借鉴 Bergemann 和 Välimäki 提出的动态枢轴机制 [5], 将多用户竞争空中计算资源的过程建模为以长期社会福利最大化为目标的动态拍卖框架。本文采用 SAC 算法学习 UAV 与移动用户的决策策略, 并利用长期 Q 函数估计用户的动态外部性, 据此构造支付规则, 以实现用户长期贡献的合理定价和系统长期社会福利最大化。

本文其余部分安排如下: 第二节介绍系统模型; 第三节给出动态拍卖问题建模; 第四节设计动态拍卖算法; 第五节给出仿真结果与分析。

2 系统模型 (System Model)

考虑由一架 UAV 和移动用户集合 $N = \{1, 2, \dots, N\}$ 组成的 UAV 辅助 MEC 系统，其中节点 0 表示 UAV，节点 $n \in N$ 表示第 n 个移动用户。系统在离散时隙中运行。在每个时隙内，UAV 基于当前系统状态联合确定目标服务位置和任务接收结果；被接收的任务经上行链路传输后由 UAV 处理，其余任务在本地完成。下文依次建立通信、计算卸载和 UAV 能耗模型。

2.1 通信模型

考虑用户 n 在时隙 t 向 UAV 上传卸载任务。UAV 与用户 n 之间的上行链路可能为视距 (LoS) 或非视距 (NLoS) 链路，其中 LoS 链路的概率表示为：

$$Pr_{n,LoS}(t) = \frac{1}{1 + \omega_1 e^{-\omega_2(\phi_n(t) - \omega_1)}} \quad (1)$$

其中， ω_1 和 ω_2 为环境常数， $\phi_n(t)$ 表示 UAV 与用户 n 之间的仰角，其定义为：

$$\phi_n(t) = \arcsin\left(\frac{z_{0,n}(t)}{(l_0(t) - l_n(t))}\right) \quad (2)$$

式中， $z_{0,n}(t)$ 为 UAV 与用户 n 之间的高度差， $l_0(t)$ 和 $l_n(t)$ 分别表示 UAV 和用户 n 的位置。相应地，NLoS 链路的概率由 LoS 概率的补集给出：

$$Pr_{n,NLoS}(t) = 1 - Pr_{n,LoS}(t) \quad (3)$$

在给定传播状态 ν 下，UAV 与用户 n 之间的路径损耗建模为

$$\chi_{0,n}(t) = \eta_\nu (l_0(t) - l_n(t))_2^{-\alpha_\nu}, \nu \in \{\text{LoS}, \text{NLoS}\} \quad (4)$$

其中， η_ν 为参考路径损耗常数， α_ν 为路径损耗指数。为刻画小尺度衰落，假设信道衰落系数服从 Nakagami- m 分布，即

$$h_{0,n}(t) \sim \text{Nakagami}(m_\nu), \nu \in \{\text{LoS}, \text{NLoS}\} \quad (5)$$

由路径损耗和小尺度衰落共同决定的信道增益为

$$g_{0,n}(t) = (h_{0,n}(t))^2 \chi_{0,n}(t) \quad (6)$$

据此，用户 n 向 UAV 的上行传输速率 $\rho_n(t)$ 可表示为

$$\rho_n(t) = B \left(1 + \frac{P_n g_{0,n}(t)}{\sigma^2}\right) \quad (7)$$

其中， B 为信道带宽， P_n 为用户 n 的发射功率， σ^2 为高斯噪声功率。若用户 n 在时隙 t 向 UAV 卸载的数据量为 $D_n(t)$ ，则对应的上传时延为

$$\tau_n^{trans}(t) = \frac{D_n(t)}{\rho_n(t)} \quad (8)$$

2.2 计算卸载模型

用户 n 在时隙 t 产生的数据量为 $D_n(t)$ 的计算任务。设单位比特任务需要 ξ 个 CPU 周期，则该任务的计算量为 $L_n(t) = D_n(t)\xi$ 。任务可在本地执行，也可卸载至 UAV 处理。

设 UAV 的总计算能力为 F^{UAV} ，并采用按任务量比例分配的计算资源分配策略。定义卸载决策变量 $x_n(t) \in \{0,1\}$ ，其中 $x_n(t) = 1$ 表示任务卸载至 UAV， $x_n(t) = 0$ 表示任务在本地执行。则 UAV 分配给用户 n 的计算频率为

$$f_n^{uav}(t) = x_n(t) \frac{D_n(t)\xi}{\sum_{k=1}^N x_k(t) D_k(t)\xi} F^{UAV}. \quad (9)$$

对于被卸载的任务，UAV 侧的计算时延为

$$\tau_n^{off}(t) = \frac{D_n(t)\xi}{f_n^{uav}(t)}. \quad (10)$$

因此，用户 n 的任务完成时延由卸载路径或本地计算路径决定，表示为

$$\tau_n(t) = x_n(t) (\tau_n^{off}(t) + \tau_n^{trans}(t)) + (1 - x_n(t)) \tau_n^{local}(t) \quad (11)$$

其中，本地计算时延为

$$\tau_n^{local}(t) = \frac{D_n(t)\xi}{f_n^{local}} \quad (12)$$

式中， f_n^{local} 为用户 n 的本地 CPU 计算频率。

2.3 UAV 能耗模型

在时隙 t 内，UAV 的能耗由飞行部署、悬停服务和任务计算三部分构成。设 P^{fly} 和 P^{hov} 分别表示 UAV 的飞行功率和悬停功率。

在时隙开始时，UAV 根据轨迹规划结果从上一位置 $l_0(t-1)$ 移动至目标位置 $l_0(t)$ 。假设 UAV 以恒定速度 V_{uav} 飞行，则移动能耗为

$$E_{move}(t) = P^{fly} \cdot \frac{(l_0(t) - l_0(t-1))}{V_{uav}} \quad (13)$$

UAV 抵达目标位置后，为被接收任务提供通信与计算服务，其悬停能耗建模为

$$E_{hov}(t) = \sum_{n=1}^N x_n(t) P^{hov} [\tau_n^{trans}(t) + \tau_n^{off}(t)] \quad (14)$$

此外，根据 CMOS 动态功耗模型，UAV 的计算能耗与分配的计算频率有关。设芯片的有效电容系数为 κ_{uav} ，则 UAV 在时隙 t 处理卸载任务的计算能耗为

$$E_{comp}(t) = \sum_{n=1}^N x_n(t) \kappa_{uav} \xi D_n(t) (f_n^{uav}(t))^2 \quad (15)$$

因此，UAV 在时隙 t 的总能耗为

$$E_0(t) = E_{move}(t) + E_{hov}(t) + E_{comp}(t) \quad (16)$$

上述模型共同决定用户任务时延与 UAV 能耗，并将在下一节用于构造参与者效用和系统社会福利。

3 问题建模 (Problem Formulation)

3.1 动态拍卖机制

为刻画 UAV 辅助 MEC 中任务接收与轨迹控制的时序耦合, 本文将系统建模为动态 VCG (Vickrey-Clarke-Groves) 拍卖问题。由于 UAV 的位置随时隙演化, 当前决策会影响后续服务条件与资源分配, 因此需要在动态过程中联合确定资源分配与支付规则。

其中, UAV 作为拍卖者 (Auctioneer), 负责分配计算资源并确定目标服务位置; 移动用户作为投标人 (Bidders), 通过申报信息竞争 UAV 计算资源。用户 n 在时隙 t 的私有类型为真实时延敏感度 $\theta_n(t) \in [0, 1]$, 向 UAV 提交的申报值记为 $\hat{\theta}_n(t)$ 。由于用户以自身效用最大化为目标, 其申报值可能偏离真实类型。

在时隙 t 开始时, 系统的公共物理状态由 UAV 与各用户在上一时隙的位置, 即 $l_0(t-1)$ 和 $l_n(t-1)$, 以及本时隙到达的任务量 $D_n(t)$ 共同构成。用户首先提交申报信息; 随后, UAV 根据当前状态和全部申报, 联合确定任务接收决策 $x_n(t)$ 与目标服务位置 $l_0(t)$ 。

动作执行后, 系统获得用户 n 在时隙 t 的任务完成时延 $\tau_n(t)$ 。据此, 用户 n 的单步效用定义为准线性形式:

$$U_n(t) = -\theta_n(t)\tau_n(t) - p_n(t) \quad (17)$$

其中, $p_n(t)$ 为该用户占用计算资源所缴纳的支付费用。进一步地, 定义 UAV 在时隙 (t) 的效用为

$$U_0(t) = \sum_{n=1}^N p_n(t) - \beta E_0(t) \quad (18)$$

其中, $E_0(t)$ 表示 UAV 在该时隙的总能耗, β 为能耗成本系数, 用于刻画能量消耗对系统效益的影响。因此, 时隙 (t) 的即时社会福利可定义为所有参与方效用之和, 即

$$W(t) = U_0(t) + \sum_{n=1}^N U_n(t) = -\sum_{n=1}^N \theta_n(t) \tau_n(t) - \beta E_0(t) \quad (19)$$

3.2 长期优化问题

在动态 UAV 辅助边缘计算场景中, 拍卖机制的设计目标不仅在于提升系统社会福利, 还需保证用户具备真实性报告的激励以及持续参与机制的意愿。UAV 侧优化问题: 从系统角度出发, UAV 作为拍卖者, 需要在各时隙联合决策任务接收和轨迹位置, 以实现长期社会福利最大化。其优化问题可表述为

$$\begin{aligned} \max_{\{x_n(t)\}, \{l_0(t)\}} \quad & \mathbb{E} \left[\sum_{t=0}^T \gamma^t W(t) \right] \\ \text{s.t.} \quad & x_n(t) \in \{0, 1\}, \quad \forall n \in N, \forall t, \\ & l_0(t) \in L, \quad \forall t. \end{aligned} \quad (20)$$

用户侧优化问题: 与 UAV 追求整体社会福利最大化不同, 用户更关注自身收益最大化。对于移动用户 n , 其策略变量为申报类型 $\hat{\theta}_n(t)$, 目标是在机制规则给定的条件下最大化自身的长期

折扣效用, 即

$$\begin{aligned} \max_{\{\hat{\theta}_n(t)\}} \quad & \mathbb{E} \left[\sum_{t=0}^T \gamma^t U_n(t) \right] \\ \text{s.t.} \quad & \hat{\theta}_n(t) \in [0, 1], \quad \forall t. \end{aligned} \quad (21)$$

综上, 本文所研究的问题可归结为: 设计联合任务卸载、支付规则与 UAV 轨迹控制的动态机制, 在兼顾用户申报激励与参与意愿的同时, 优化系统长期社会福利。

4 算法设计 (Algorithm Design)

4.1 多智能体 POSG 建模

为求解前述长期社会福利优化问题, 本文将 UAV 辅助 MEC 系统建模为部分可观测随机博弈 (Partially Observable Stochastic Game, POSG)。在该框架下, UAV 根据用户申报学习任务接收与轨迹控制策略, 各移动用户则基于局部信息学习申报策略。该博弈记为 $G = \langle I, S, \{Z_i\}_{i \in I}, \{A_i\}_{i \in I}, P, \{r_i\}_{i \in I}, \gamma \rangle$, 其中, I 、 S 、 Z_i 和 A_i 分别表示智能体集合、全局状态空间、智能体 i 的局部观测空间和动作空间; $P(s(t+1) | s(t), a(t))$ 为状态转移概率, r_i 为即时奖励函数, γ 为折扣因子。智能体集合为 $I = \{0\} \cup N$, 其中 0 表示 UAV 智能体。为描述环境状态, 时隙 t 的全局状态定义为

$$s(t) = \{l_0(t-1), \{l_n(t-1)\}_{n=1}^N, \{D_n(t)\}_{n=1}^N, \{\theta_n(t)\}_{n=1}^N\}. \quad (22)$$

4.1.1 UAV 智能体

UAV 在时隙 t 的局部观测为

$$o_0(t) = \{l_0(t-1), \{l_n(t-1)\}_{n=1}^N, \{D_n(t)\}_{n=1}^N, \{\hat{\theta}_n(t)\}_{n=1}^N\}. \quad (23)$$

其动作为任务接收与目标服务位置构成的联合控制动作:

$$a_0(t) = (\{x_n(t)\}_{n=1}^N, l_0(t)). \quad (24)$$

UAV 的即时奖励取为系统即时社会福利:

$$r_0(t) = W(t) \quad (25)$$

4.1.2 移动用户智能体

第 n 个移动用户在时隙 t 的局部观测为

$$o_n(t) = \{l_n(t-1), l_0(t-1), D_n(t), \theta_n(t)\}. \quad (26)$$

任务量 $D_n(t)$ 和真实时延敏感度 $\theta_n(t)$ 使用户能够根据信息状态调整申报策略。用户的动作为向 UAV 提交的时延敏感度申报:

$$a_n(t) = \hat{\theta}_n(t). \quad (27)$$

其即时奖励定义为单时隙效用:

$$r_n(t) = U_n(t). \quad (28)$$

在每个时隙开始时, 环境给定全局状态 $s(t)$ 。各移动用户基于 $o_n(t)$ 生成申报动作 $a_n(t)$, UAV 接收全部申报后依据策略 $\pi_0(a_0(t) | o_0(t))$ 生成联合控制动作 $a_0(t)$ 。随后, 环境执行任务卸载、传输与计算, 得到用户时延 $\tau_n(t)$ 和相应的动态 VCG 支付 $p_n(t)$, 并依据上述奖励函数反馈各智能体。最后, 环境转移至 $s(t+1)$, 训练过程利用该转移更新策略。

4.2 基于 SAC 的策略学习

UAV 依赖策略 $\pi_0(a_0(t) | o_0(t))$ 将局部观测转化为联合控制动作, 而各移动用户 n 则通过策略 $\pi_n(a_n(t) | o_n(t))$ 生成相应的竞标动作。给定 UAV 的局部观测 $o_n(t)$ 和联合控制动作 $a_0(t)$, 在系统联合策略 $(\pi_0, \pi_n, \forall n \in N)$ 下, UAV 的状态-动作值函数 (Q函数) 定义为:

$$Q_0(o_0(t), a_0(t)) = \max_{\pi_0} \mathbb{E} \left[\sum_{\nu=t}^T \gamma^{\nu-t} r_0(\nu) | o_0(t), a_0(t) \right] \quad (29)$$

其中, $\mathbb{E}[\cdot]$ 表示对未来所有轮次状态演化和动作选择的期望, γ 为折扣因子。最优化该 Q 值的最佳响应策略 π_0^* 表示为:

$$\pi_0^* = \arg \max_{\pi_0} Q_0(o_0(t), a_0(t)) \quad (30)$$

同理, 给定移动用户 n 的局部观测 $o_n(t)$ 和动作 $a_n(t)$, 用户 n 的 Q 函数定义为:

$$Q_n(o_n(t), a_n(t)) = \max_{\pi_n} \mathbb{E} \left[\sum_{\nu=t}^T \gamma^{\nu-t} r_n(\nu) | o_n(t), a_n(t) \right] \quad (31)$$

用户 n 的最佳响应策略 π_n^* 则表示为:

$$\pi_n^* = \arg \max_{\pi_n} Q_n(o_n(t), a_n(t)) \quad (32)$$

针对动态环境下联合决策变量连续、系统状态随时间演化且难以获得精确解析解的问题, 本文采用 Soft Actor-Critic (SAC) 算法求解长期优化策略。与传统强化学习仅最大化期望累积回报不同, SAC 在目标函数中引入策略熵项, 以鼓励策略保持适当随机性, 避免过早收敛到局部最优。其最大熵目标函数可表示为

$$J(\pi_m) = E_{a_m \sim \pi_m} \left(\sum_{\nu=t}^T \gamma^{\nu-t} (r_m(\nu) - \alpha \pi_m(a_m(\nu) | o_m(\nu))) \right) \quad (33)$$

$m \in \{0, 1, \dots, N\}$ 代表 UAV 和移动用户智能体。在最大熵强化学习框架下, 第 m 个智能体对应的状态价值函数可表示为

$$V_m(o_m(t)) = E_{a_m(t) \sim \pi_m} (Q_m(o_m(t), a_m(t); \hat{\omega}_m) - \alpha \pi_m(a_m(t) | o_m(t); \psi_m)) \quad (34)$$

其中, $\hat{\omega}_m$ 表示目标 Q 网络参数, ψ_m 表示策略网络参数。由此, 第 m 个智能体的时序差分目标可进一步写为

$$y_m(t) = r_m(t) + \gamma V_m(o_m(t+1)) \quad (35)$$

基于上述 TD target, Q 网络损失函数定义为

$$L(\omega_m) = E_{(o_m(t), a_m(t), r_m(t), o_m(t+1)) \sim D_m} \left(\frac{1}{2} (Q_m(o_m(t), a_m(t); \omega_m) - y_m(t))^2 \right) \quad (36)$$

其中, ω_m 表示第 m 个智能体在线 Q 网络的参数, D_m 表示其经验回放池。策略网络损失函数可以表示为

$$L(\psi_m) = E_{o_m(t) \sim D_m, a_m(t) \sim \pi_m} (\alpha \pi_m(a_m(t) | o_m(t); \psi_m) - Q_m(o_m(t), a_m(t); \omega_m)) \quad (37)$$

该损失函数表明, 策略网络在更新过程中不仅倾向于选择具有较高动作价值的行为, 同时在熵项作用下保持适当的随机性, 从而在探索与利用之间取得平衡。基于上述损失函数, 第 m 个智能体的在线 Q 网络参数和目标 Q 网络可通过梯度下降方式更新为

$$\omega_m \leftarrow \omega_m - \eta_Q \nabla_{\omega_m} L(\omega_m), \quad (38)$$

$$\hat{\omega}_m \leftarrow \rho \omega_m + (1 - \rho) \hat{\omega}_m, \quad (39)$$

其中, η_Q 表示 Q 网络的学习率。目标 Q 网络参数 $\hat{\omega}_m$ 采用软更新方式迭代。类似地, 策略网络参数 ψ_m 通过最小化策略损失函数进行更新, 即

$$\psi_m \leftarrow \psi_m - \eta_\pi \nabla_{\psi_m} L(\psi_m) \quad (40)$$

其中, η_π 表示策略网络的学习率。为了使策略熵在训练过程中能够自动调节, SAC 通常采用温度参数 α_m 的自适应更新机制。设目标熵为 H_m , 则对应的损失函数可写为

$$L(\alpha_m) = E_{o_m(t) \sim D_m, a_m(t) \sim \pi_m} (-\alpha_m \pi_m(a_m(t) | o_m(t); \psi_m) - \alpha_m H_m) \quad (41)$$

对于温度参数 α_m , 其更新方式为

$$\alpha_m \leftarrow \alpha_m - \eta_\alpha \nabla_{\alpha_m} L(\alpha_m), \quad (42)$$

其中, η_α 表示温度参数的学习率。

4.3 基于动态 VCG 的定价规则

为刻画用户 n 对其余参与者造成的跨期外部性, 本文借鉴动态枢轴机制构造支付规则 [5]。给定 UAV 动作 $a_0(t)$, 用户 k 在时隙 t 的当期价值定义为

$$v_k(a_0(t); \theta_k(t)) = -\theta_k(t) \tau_k(a_0(t), t), \quad k \in N. \quad (43)$$

UAV 的当期价值为 $v_0(a_0(t)) = -\beta E_0(t; a_0(t))$ 。记 $\theta_{-n}(t) = \{\theta_k(t)\}_{k \in N \setminus \{n\}}$ 为剩余用户的类型向量, 则反事实环境中的即时社会福利为

$$W^{-n}(a_0(t); \theta_{-n}(t)) = v_0(a_0(t)) + \sum_{k \in N \setminus \{n\}} v_k(a_0(t); \theta_k(t)). \quad (44)$$

记 $\mathcal{W}^{-n}(t+1 | a_0(t))$ 为从下一时隙起的期望长期社会福利； $a_0^*(t)$ 和 $a_0^{*, -n}(t)$ 分别为完整系统和反事实系统中的最优动作。将 $a_0^*(t)$ 限制到反事实环境的动作记为 $\bar{a}_0^{-n}(t)$ 。为简洁起见，以下以 $v_j(a)$ 表示时隙 t 内参与者 j 在动作 a 下的当期价值。则用户 n 的动态枢轴支付为

$$p_n(t) = \sum_{j \in I \setminus \{n\}} \left[v_j(a_0^{*, -n}(t)) - v_j(\bar{a}_0^{-n}(t)) \right] + \gamma \left[\mathcal{W}^{-n}(t+1 | a_0^{*, -n}(t)) - \mathcal{W}^{-n}(t+1 | \bar{a}_0^{-n}(t)) \right]. \quad (45)$$

上式第一项度量用户 n 对其余参与者当期价值的影响，第二项刻画该影响对后续系统演化的延续。为避免显式求解延续社会福利，本文在反事实环境中以 $W^{-n}(a_0(t); \theta_{-n}(t))$ 作为 UAV 的奖励，即 $r_0^{-n}(t) = W^{-n}(a_0(t); \theta_{-n}(t))$ ，并学习相应的长期 Q 函数：

$$Q_0^{-n}(o_0^{-n}(t), a_0(t)) = \mathbb{E} \left[\sum_{\nu=t}^T \gamma^{\nu-t} W^{-n}(a_0(\nu); \theta_{-n}(\nu)) \mid o_0^{-n}(t), a_0(t) \right]. \quad (46)$$

其中，反事实环境中的最优动作满足

$$a_0^{*, -n}(t) = \arg \max_{a_0(t)} Q_0^{-n}(o_0^{-n}(t), a_0(t)). \quad (47)$$

因此，上述动态枢轴支付可等价地形式化为两个反事实长期 Q 值之差：

$$p_n(t) = Q_0^{-n}(o_0^{-n}(t), a_0^{*, -n}(t)) - Q_0^{-n}(o_0^{-n}(t), \bar{a}_0^{-n}(t)). \quad (48)$$

4.4 反事实子拍卖采样与 Q 函数更新

在每个训练时隙，算法采用 ϵ -贪婪规则采样反事实索引。其采样规则为： $\kappa = 0$ ，概率为 $1 - \epsilon$ ；否则， $\kappa \in \{1, \dots, N\}$ 均匀采样。在完整环境分支中，所有用户提交报告，UAV 基于完整报告状态选择联合动作。在反事实分支中，抽取的用户被移除，并构造对应的掩码报告状态；UAV 策略网络据此生成子拍卖动作。完整环境转移分别写入 UAV 和各用户的经验回放池；反事实分支仅将 UAV 转移 $(o_0^{-n}(t), a_0(t), r_0^{-n}(t), o_0^{-n}(t+1))$ 写入 UAV 回放池。对于任一用户，反事实 Q 函数表示该用户被移除后剩余系统的期望折扣累计社会福利。其最优反事实 Q 值计算为

$$Q_0^{-n,*}(t) = \max_a Q_0^{-n}(o_0^{-n}(t), a). \quad (49)$$

再将完整系统的最优动作限制到反事实环境中，并代入式 (48) 计算支付。

算法 1 动态 VCG 多智能体强化学习训练

-
- 1: 初始化所有策略网络、价值网络和目标网络参数。
 - 2: **for** $t = 1, 2, \dots, T$ **do**
 - 3: 按 ϵ -贪婪规则采样反事实索引 κ 。
 - 4: $\kappa \leftarrow 0$ 的概率为 $1 - \epsilon$; 否则, $\kappa \sim \text{Unif}(\{1, \dots, N\})$ 。

阶段 1: 用户申报

- 5: **for all** $n \in N$ **do**
- 6: $a_n(t) \sim \pi_n(\cdot \mid o_n(t))$ 。
- 7: $\hat{\theta}_n(t) \leftarrow a_n(t)$ 。
- 8: **end for**
- 9: 构造 UAV 观测 $o_0(t)$ 。

阶段 2: UAV 决策

- 10: **if** $\kappa = 0$ **then**
- 11: $a_0(t) \sim \pi_0(\cdot \mid o_0(t))$ 。
- 12: **else**
- 13: 构造掩码申报状态 $o_0^{-\kappa}(t)$ 。
- 14: $a_0(t) \sim \pi_0(\cdot \mid o_0^{-\kappa}(t))$ 。
- 15: **end if**

阶段 3: 动态 VCG 定价

- 16: **for all** $n \in N$ **do**
- 17: 通过掩码用户 n 构造 $o_0^{-n}(t)$ 。
- 18: $Q_0^{-n,*}(t) \leftarrow \max_a Q_0^{-n}(o_0^{-n}(t), a)$ 。
- 19: $a_0^*(t) \leftarrow \arg \max_a Q_0(o_0(t), a)$ 。
- 20: $\bar{a}_0^{-n}(t) \leftarrow a_0^*(t)|_{-n}$ 。
- 21: $Q_0^{-n}(t, \bar{a}_0^{-n}(t)) \leftarrow Q_0^{-n}(o_0^{-n}(t), \bar{a}_0^{-n}(t))$ 。
- 22: $p_n(t) \leftarrow Q_0^{-n,*}(t) - Q_0^{-n}(t, \bar{a}_0^{-n}(t))$ 。
- 23: **end for**
- 24: 执行联合动作 $a_0(t)$, 获得奖励 $\{r_n(t)\}_{n=0}^N$ 与下一观测 $\{o_n(t+1)\}_{n=0}^N$ 。

阶段 4: 经验回放池更新

- 25: **if** $\kappa = 0$ **then**
 - 26: 将 UAV 转移 $(o_0(t), a_0(t), r_0(t), o_0(t+1))$ 存入 $\mathcal{B}_0$ 。
 - 27: **for all** $n \in N$ **do**
 - 28: 将用户转移 $(o_n(t), a_n(t), r_n(t), o_n(t+1))$ 存入 $\mathcal{B}_n$ 。
 - 29: **end for**
 - 30: **else**
 - 31: 将 UAV 反事实转移 $(o_0^{-\kappa}(t), a_0(t), r_0^{-\kappa}(t), o_0^{-\kappa}(t+1))$ 存入 $\mathcal{B}_0$ 。
 - 32: **end if**
 - 33: **end for**
-

5 仿真结果与分析 (Simulation Results and Analysis)

6 参考文献 (References)

- [1] S. Cheng, T. Ren, and H. Zhang. A stackelberg-game-based framework for edge pricing and resource allocation in mobile edge computing. *IEEE Internet of Things Journal*, 11(11):20514–20530, 2024.
- [2] J. Xiao, Q. Gao, and Z. Yang. Multi-round auction-based resource allocation for edge computing: Maximizing social welfare. *Future Generation Computer Systems*, 140:365–375, 2023.
- [3] Q. Li, Z. Wang, and H. Du. Incentive mechanism design for value-decreasing tasks in dynamic competitive edge computing networks. *Journal of Combinatorial Optimization*, 49(1):3, 2025.
- [4] Leijie Wu, Song Guo, Zicong Hong, Yi Liu, Wenchao Xu, and Yufeng Zhan. Long-term adaptive VCG auction mechanism for sustainable federated learning with periodical client shifting. *IEEE Transactions on Mobile Computing*, 23(5):6060–6074, 2024.
- [5] Dirk Bergemann and Juuso Välimäki. The dynamic pivot mechanism. *Econometrica*, 78(2):771–789, 2010.