

面向长期外部性的无人机辅助任务卸载动态激励机制

李锡泽

摘要

在地面基站覆盖不足区域，无人机（UAV）可作为空中移动边缘服务器，为多个移动用户提供计算卸载服务。本文考虑任务动态到达、UAV 位置随时隙演化且机载计算与能量资源有限的场景。在该系统中，UAV 服务平台既是计算服务提供方，也是机制的执行主体，负责接收用户提交的私有延迟敏感类型报告，并据此作出任务接收、服务位置和计算资源分配决策；移动用户作为机制参与者提交类型报告并接受计算服务。UAV 与用户因此形成动态博弈，双方优化目标不同：UAV 服务平台以最大化长期折扣社会福利为目标，用户则以最大化自身长期折扣效用为目标。由于用户的类型报告会影响任务接收和资源分配，用户有动机通过策略性上报降低自身延迟或支付、提高个体效用；虚报信息会误导 UAV 决策，损害系统资源配置效率和长期社会福利。为解决上述问题，本文提出由 UAV 服务平台执行的面向长期外部性的动态激励机制，将 UAV 服务平台和各移动用户均建模为智能体，构建部分可观测随机博弈（POSG）。采用多智能体离散动作 Soft Actor-Critic（SAC）训练上述智能体：UAV 智能体学习任务接收与轨迹控制策略，各移动用户智能体学习类型上报策略。在此基础上，机制联合设计任务卸载、轨迹控制与支付规则；针对每个用户构造移除该用户的反事实环境，利用反事实长期 Q 值评估该用户对其余参与者的跨期外部性，并据此计算该用户的长期外部性支付，同时通过随机采样反事实分支减少重复环境交互。仿真结果表明，在所设条件下，所提方法相较即时 VCG 定价基线和无定价基线取得更高且更稳定的 UAV 平均训练回报，同时降低用户平均绝对上报误差，抑制策略性虚报，表现出更强的如实上报倾向和近似激励相容性。

关键词：无人机辅助移动边缘计算；动态激励机制；多智能体强化学习

1 引言（Introduction）

现有移动设备受限于物理体积和本地算力，难以满足 5G 场景下不断增长的计算需求。移动边缘计算（Mobile Edge Computing, MEC）通过将计算任务卸载至邻近边缘服务器，为资源受限设备提供了有效支撑。在 UAV 辅助 MEC 网络中，UAV 可作为空中移动边缘服务器，为地面基站覆盖不足区域的移动用户提供灵活的卸载服务。近年来，相关研究已从联合任务卸载与 UAV 部署、UAV 高度设计，以及用户关联和卸载决策协同优化等角度提升 UAV 辅助 MEC 的服务能力 [1–3]。然而，UAV 需要承担飞行、通信和计算成本，用户也具有追求自身效用最大化的自利性。因此，有必要设计合理的激励机制，以促进服务提供方与任务请求方持续参与计算卸载。

在 MEC 场景中，拍卖机制能够将任务请求方的服务需求与边缘服务提供方的计算、通信资源统一纳入资源配置和支付规则设计，其核心目标通常是最大化交易产生的社会福利。双边拍卖允许任务请求方和服务提供方分别提交报价与要价，通过供需匹配确定交易对象和资源分

配结果；组合拍卖则允许参与者对任务、带宽和计算资源等组合提交偏好，从而适应 MEC 中资源需求的多维耦合特征。相关研究已从多轮资源交易、组合竞价和临界价格支付等方面提升边缘资源配置效率。例如，Xiao 等研究了面向边缘计算的多轮拍卖资源分配问题，以社会福利最大化为目标协调多用户与多服务器之间的供需关系 [4]；Su 等面向工业物联网中的移动边缘计算提出真实组合拍卖机制，在组合资源配置中兼顾真实性与社会福利最大化 [5]。这些研究说明，拍卖机制能够在分散私有信息条件下实现较高效的边缘资源配置，并为计算卸载中的激励设计提供了重要基础。

然而，上述双边拍卖和真实组合拍卖大多将一次拍卖视为相对独立的单轮决策，主要根据当前时刻的报价、要价和资源状态确定获胜者与支付。该假设难以充分反映 UAV 辅助 MEC 的动态特征：UAV 在当前时隙调整服务位置会改变后续时隙的信道质量、覆盖范围和飞行能耗，当前任务接收结果也会影响下一时隙的资源竞争、任务状态及用户参与情况。因此，若在每个时隙分别最大化即时交易福利，机制可能产生短视的资源配置结果，无法评价当前参与者对未来系统状态和其他参与者福利的持续影响。对于此类跨时隙交互场景，仅依靠一次性拍卖的定价规则难以支撑长期有效的激励。

Vickrey-Clarke-Groves (VCG) 拍卖通过向参与者收取其对其他参与者造成的外部性，在实现有效资源配置的同时，为真实报告提供激励，因而成为社会福利最大化导向的典型机制。针对具有连续参与过程的联邦学习场景，Wu 等提出长期自适应 VCG 拍卖机制，将客户端选择与长期社会福利优化相结合，并考虑周期性客户端迁移对参与决策的影响 [6]。不过，该工作的定价仍主要依据当前时隙的社会福利外部性，尚未显式刻画当前参与或类型报告对后续状态演化、资源分配和累计社会福利的影响。在 UAV 辅助 MEC 中，这一局限尤为突出，因为 UAV 位置和有限能量会使当前决策持续作用于未来多个时隙。

针对上述问题，本文借鉴动态枢轴机制的思想 [7]，提出面向跨期外部性的 UAV 辅助 MEC 动态激励机制。本文不再以当前时隙的福利差异作为唯一计价依据，而是构造包含未来状态转移的反事实环境，利用长期 Q 值评估某一用户参与后对其余参与者累计折扣社会福利的影响，并据此确定长期外部性支付。这样既能够反映 UAV 位置演化和资源竞争带来的跨期影响，也能够将用户的长期报告激励与系统的长期社会福利目标联系起来。

本文的主要贡献概括如下：

- 面向任务动态到达、UAV 位置随时隙演化且资源受限的 UAV 辅助 MEC 场景，构建包含 UAV 服务平台和移动用户的长期动态激励模型，将任务接收、服务位置、类型报告与支付规则纳入统一的社会福利优化框架。
- 提出基于反事实长期 Q 值的跨期外部性定价方法。通过比较完整环境与移除特定用户后的反事实环境，刻画该用户对其他参与者长期累计福利的影响，从而将传统即时 VCG 定价扩展到具有状态演化的动态卸载过程。
- 将上述机制建模为部分可观测随机博弈，采用多智能体离散动作 SAC 联合学习 UAV 的任务接收与服务位置策略以及用户的类型报告策略，并通过随机采样反事实分支降低长期外部性估计所需的重复环境交互。
- 通过仿真实验与即时 VCG 定价和无定价基线进行比较，验证所提机制在 UAV 长期训练

回报、用户上报误差和策略性虚报抑制方面的有效性，说明跨期外部性定价能够改善动态 MEC 中的资源配置与参与激励。

本文其余部分安排如下：第二节介绍系统模型；第三节给出动态激励机制建模；第四节设计相应的学习与支付算法；第五节给出仿真结果与分析。

2 系统模型 (System Model)

考虑由一架 UAV 和移动用户集合 $N = \{1, 2, \dots, N\}$ 组成的 UAV 辅助 MEC 系统，其中节点 0 表示 UAV，节点 $n \in N$ 表示第 n 个移动用户。系统在离散时隙中运行。在每个时隙内，UAV 基于当前系统状态联合确定目标服务位置和任务接收结果；被接收的任务经上行链路传输后由 UAV 处理，其余任务在本地完成。下文依次建立通信、计算卸载和 UAV 能耗模型。

2.1 通信模型

考虑用户 n 在时隙 t 向 UAV 上传卸载任务。UAV 与用户 n 之间的上行链路可能为视距 (LoS) 或非视距 (NLoS) 链路，其中 LoS 链路的概率表示为：

$$Pr_{n,LoS}(t) = \frac{1}{1 + \mu_1 e^{-\mu_2(\phi_n(t) - \mu_1)}} \quad (1)$$

其中， μ_1 和 μ_2 为环境常数， $\phi_n(t)$ 表示 UAV 与用户 n 之间的仰角，其定义为：

$$\phi_n(t) = \arcsin\left(\frac{z_{0,n}(t)}{(l_0(t) - l_n(t))}\right) \quad (2)$$

式中， $z_{0,n}(t)$ 为 UAV 与用户 n 之间的高度差， $l_0(t)$ 和 $l_n(t)$ 分别表示 UAV 和用户 n 的位置。相应地，NLoS 链路的概率由 LoS 概率的补集给出 [8]：

$$Pr_{n,NLoS}(t) = 1 - Pr_{n,LoS}(t) \quad (3)$$

在给定传播状态 ν 下，UAV 与用户 n 之间的路径损耗建模为

$$\chi_{0,n}(t) = \eta_\nu (l_0(t) - l_n(t))_2^{-\alpha_\nu}, \nu \in \{\text{LoS}, \text{NLoS}\} \quad (4)$$

其中， η_ν 为参考路径损耗常数， α_ν 为路径损耗指数。为刻画小尺度衰落，假设信道衰落系数服从 Nakagami- m 分布，即

$$h_{0,n}(t) \sim \text{Nakagami}(m_\nu), \nu \in \{\text{LoS}, \text{NLoS}\} \quad (5)$$

由路径损耗和小尺度衰落共同决定的信道增益为

$$g_{0,n}(t) = (h_{0,n}(t))^2 \chi_{0,n}(t) \quad (6)$$

据此，用户 n 向 UAV 的上行传输速率 $\rho_n(t)$ 可表示为

$$\rho_n(t) = B \left(1 + \frac{P_n g_{0,n}(t)}{\sigma^2}\right) \quad (7)$$

其中， B 为信道带宽， P_n 为用户 n 的发射功率， σ^2 为高斯噪声功率。若用户 n 在时隙 t 向 UAV 卸载的数据量为 $D_n(t)$ ，则对应的上传时延为

$$\tau_n^{trans}(t) = \frac{D_n(t)}{\rho_n(t)} \quad (8)$$

2.2 计算卸载模型

用户 n 在时隙 t 产生的数据量为 $D_n(t)$ 的计算任务。设单位比特任务需要 ξ 个 CPU 周期, 则该任务的计算量为 $L_n(t) = D_n(t)\xi$ 。任务可在本地执行, 也可卸载至 UAV 处理 [9]。

设 UAV 的总计算能力为 F_{uav} , 并采用按任务量比例分配的计算资源分配策略。定义卸载决策变量 $x_n(t) \in \{0, 1\}$, 其中 $x_n(t) = 1$ 表示任务卸载至 UAV, $x_n(t) = 0$ 表示任务在本地执行。则 UAV 分配给用户 n 的计算频率为

$$f_n^{\text{uav}}(t) = x_n(t) \frac{D_n(t)\xi}{\sum_{k=1}^N x_k(t) D_k(t)\xi} F_{\text{uav}}. \quad (9)$$

对于被卸载的任务, UAV 侧的计算时延为

$$\tau_n^{\text{off}}(t) = \frac{D_n(t)\xi}{f_n^{\text{uav}}(t)}. \quad (10)$$

因此, 用户 n 的任务完成时延由卸载路径或本地计算路径决定, 表示为

$$\tau_n(t) = x_n(t) (\tau_n^{\text{off}}(t) + \tau_n^{\text{trans}}(t)) + (1 - x_n(t)) \tau_n^{\text{local}}(t) \quad (11)$$

其中, 本地计算时延为

$$\tau_n^{\text{local}}(t) = \frac{D_n(t)\xi}{f_n^{\text{local}}} \quad (12)$$

式中, f_n^{local} 为用户 n 的本地 CPU 计算频率。

2.3 UAV 能耗模型

在时隙 t 内, UAV 的能耗由飞行部署、悬停服务和任务计算三部分构成。设 P^{fly} 和 P^{hov} 分别表示 UAV 的飞行功率和悬停功率。

在时隙开始时, UAV 根据轨迹规划结果从上一位置 $l_0(t-1)$ 移动至目标位置 $l_0(t)$ 。假设 UAV 以恒定速度 V_{uav} 飞行, 则移动能耗为

$$E_{\text{move}}(t) = P^{\text{fly}} \cdot \frac{(l_0(t) - l_0(t-1))}{V_{\text{uav}}} \quad (13)$$

UAV 抵达目标位置后, 为被接收任务提供通信与计算服务, 其悬停能耗建模为

$$E_{\text{hov}}(t) = \sum_{n=1}^N x_n(t) P^{\text{hov}} [\tau_n^{\text{trans}}(t) + \tau_n^{\text{off}}(t)] \quad (14)$$

此外, 根据 CMOS 动态功耗模型, UAV 的计算能耗与分配的计算频率有关 [10]。设芯片的有效电容系数为 κ_{uav} , 则 UAV 在时隙 t 处理卸载任务的计算能耗为

$$E_{\text{comp}}(t) = \sum_{n=1}^N x_n(t) \kappa_{\text{uav}} \xi D_n(t) (f_n^{\text{uav}}(t))^2 \quad (15)$$

因此, UAV 在时隙 t 的总能耗为

$$E_0(t) = E_{\text{move}}(t) + E_{\text{hov}}(t) + E_{\text{comp}}(t) \quad (16)$$

上述模型共同决定用户任务时延与 UAV 能耗, 并将在下一节用于构造参与者效用和系统社会福利。

3 问题建模 (Problem Formulation)

3.1 动态激励机制

为刻画 UAV 辅助 MEC 中任务接收与轨迹控制的时序耦合, 本文构建基于类型报告和外部性定价的长期动态激励机制 [11]。由于 UAV 的位置随时隙演化, 当前决策会影响后续服务条件与资源分配, 因此需要在动态过程中联合确定资源分配与支付规则。

其中, UAV 作为服务平台, 负责分配计算资源并确定目标服务位置; 移动用户作为机制参与者, 通过类型上报参与 UAV 计算资源分配。用户 n 在时隙 t 的私有类型为真实时延敏感度 $\theta_n(t) \in [0, 1]$, 向 UAV 提交的类型报告记为 $\hat{\theta}_n(t)$ 。由于用户以自身效用最大化为目标, 其上报值可能偏离真实类型。

在时隙 t 开始时, 系统的公共物理状态由 UAV 与各用户在上一时隙的位置, 即 $l_0(t-1)$ 和 $l_n(t-1)$, 以及本时隙到达的任务量 $D_n(t)$ 共同构成。用户首先提交上报信息; 随后, UAV 根据当前状态和全部上报, 联合确定任务接收决策 $x_n(t)$ 与目标服务位置 $l_0(t)$ 。

动作执行后, 系统获得用户 n 在时隙 t 的任务完成时延 $\tau_n(t)$ 。据此, 用户 n 的单步效用定义为准线性形式:

$$U_n(t) = -\theta_n(t)\tau_n(t) - p_n(t) \quad (17)$$

其中, $p_n(t)$ 为该用户占用计算资源所缴纳的支付费用。进一步地, 定义 UAV 在时隙 t 的效用为

$$U_0(t) = \sum_{n=1}^N p_n(t) - \beta E_0(t) \quad (18)$$

其中, $E_0(t)$ 表示 UAV 在该时隙的总能耗, β 为能耗成本系数, 用于刻画能量消耗对系统效益的影响。因此, 时隙 t 的即时社会福利可定义为所有参与方效用之和, 即

$$W(t) = U_0(t) + \sum_{n=1}^N U_n(t) = -\sum_{n=1}^N \theta_n(t)\tau_n(t) - \beta E_0(t) \quad (19)$$

3.2 长期优化问题

在动态 UAV 辅助边缘计算场景中, 任务到达、用户状态与 UAV 位置均随时间演化, 当前决策不仅影响即时资源配置结果, 还会改变后续时隙的系统状态。因此, 动态激励机制需要同时考虑系统层面的长期资源配置效率与用户层面的个体决策激励, 在优化长期社会福利的同时, 兼顾用户的类型上报激励与持续参与意愿。基于上述目标, 本文分别从 UAV 服务平台和移动用户两个层面构建长期优化问题。

UAV 侧长期社会福利优化: 作为服务平台, UAV 根据当前系统状态与用户类型报告, 在各时隙联合确定任务接收决策和目标服务位置。为刻画当前决策对未来系统演化的影响, UAV 以期

望折扣累计社会福利最大化为目标，其优化问题表述为

$$\begin{aligned} \max_{\{x_n(t)\}, \{l_0(t)\}} \quad & \mathbb{E} \left[\sum_{t=0}^T \gamma^t W(t) \right] \\ \text{s.t.} \quad & x_n(t) \in \{0, 1\}, \quad \forall n \in N, \forall t, \\ & l_0(t) \in L, \quad \forall t. \end{aligned} \quad (20)$$

其中， $\gamma \in [0, 1)$ 为折扣因子， $\mathbb{E}[\cdot]$ 表示对任务到达、状态转移及策略随机性等不确定因素取期望；约束条件分别限定任务接收变量的取值范围和 UAV 的可选服务位置。

用户侧长期效用优化：移动用户作为具有自利性的机制参与者，其决策目标并非直接最大化系统社会福利，而是在给定机制规则及其他参与者策略的条件下最大化自身效用。对于任意用户 n ，其决策变量为各时隙提交的类型报告 $\hat{\theta}_n(t)$ ，相应的长期优化问题表述为

$$\begin{aligned} \max_{\{\hat{\theta}_n(t)\}} \quad & \mathbb{E} \left[\sum_{t=0}^T \gamma^t U_n(t) \right] \\ \text{s.t.} \quad & \hat{\theta}_n(t) \in [0, 1], \quad \forall t. \end{aligned} \quad (21)$$

用户效用 $U_n(t)$ 同时取决于任务完成时延和支付，因此，支付规则会直接影响用户的类型报告策略。综上，本文旨在联合设计任务接收、UAV 轨迹控制与支付规则，协调平台侧的长期社会福利目标和用户侧的长期效用目标，从而在兼顾用户上报激励与参与意愿的同时，提高系统的长期资源配置效率。

4 算法设计 (Algorithm Design)

4.1 多智能体部分可观测随机博弈建模

为求解前述长期社会福利优化问题，本文将 UAV 辅助 MEC 系统建模为部分可观测随机博弈 (Partially Observable Stochastic Game, POSG)。在该框架下，UAV 根据用户上报学习任务接收与轨迹控制策略，各移动用户则基于局部信息学习上报策略。该博弈记为 $G = \langle I, S, \{Z_i\}_{i \in I}, \{A_i\}_{i \in I}, P, \{r_i\}_{i \in I}, \gamma \rangle$ ，其中， I 、 S 、 Z_i 和 A_i 分别表示智能体集合、全局状态空间、智能体 i 的局部观测空间和动作空间； $P(s(t+1) | s(t), a(t))$ 为状态转移概率， r_i 为即时奖励函数， γ 为折扣因子。智能体集合为 $I = \{0\} \cup N$ ，其中 0 表示 UAV 智能体。为描述环境状态，时隙 t 的全局状态定义为

$$s(t) = \{l_0(t-1), \{l_n(t-1)\}_{n=1}^N, \{D_n(t)\}_{n=1}^N, \{\theta_n(t)\}_{n=1}^N\}. \quad (22)$$

4.1.1 UAV 智能体

UAV 在时隙 t 的局部观测为

$$o_0(t) = \{l_0(t-1), \{l_n(t-1)\}_{n=1}^N, \{D_n(t)\}_{n=1}^N, \{\hat{\theta}_n(t)\}_{n=1}^N\}. \quad (23)$$

其动作为任务接收与目标服务位置构成的联合控制动作：

$$a_0(t) = (\{x_n(t)\}_{n=1}^N, l_0(t)). \quad (24)$$

UAV 的即时奖励取为系统即时社会福利:

$$r_0(t) = W(t) \quad (25)$$

4.1.2 移动用户智能体

第 n 个移动用户在时隙 t 的局部观测为

$$o_n(t) = \{l_n(t-1), l_0(t-1), D_n(t), \theta_n(t)\}. \quad (26)$$

任务量 $D_n(t)$ 和真实时延敏感度 $\theta_n(t)$ 使用户能够根据信息状态调整上报策略。用户的动作为向 UAV 提交的时延敏感度上报:

$$a_n(t) = \hat{\theta}_n(t). \quad (27)$$

其即时奖励定义为单时隙效用:

$$r_n(t) = U_n(t). \quad (28)$$

在每个时隙开始时, 环境给定全局状态 $s(t)$ 。各移动用户基于 $o_n(t)$ 生成类型上报动作 $a_n(t)$, UAV 接收全部上报后依据策略 $\pi_0(a_0(t) | o_0(t))$ 生成联合控制动作 $a_0(t)$ 。随后, 环境执行任务卸载、传输与计算, 得到用户时延 $\tau_n(t)$ 和相应的长期外部性支付 $p_n(t)$, 并依据上述奖励函数反馈各智能体。最后, 环境转移至 $s(t+1)$, 训练过程利用该转移更新策略。

4.2 基于 SAC 的策略学习

UAV 依赖策略 $\pi_0(a_0(t) | o_0(t))$ 将局部观测转化为联合控制动作, 而各移动用户 n 则通过策略 $\pi_n(a_n(t) | o_n(t))$ 生成相应的上报动作。给定 UAV 的局部观测 $o_0(t)$ 和联合控制动作 $a_0(t)$, 在系统联合策略 $(\pi_0, \pi_n, \forall n \in N)$ 下, UAV 的状态-动作值函数 (Q 函数) 定义为:

$$Q_0(o_0(t), a_0(t)) = \max_{\pi_0} \mathbb{E} \left[\sum_{\nu=t}^T \gamma^{\nu-t} r_0(\nu) | o_0(t), a_0(t) \right] \quad (29)$$

其中, $\mathbb{E}[\cdot]$ 表示对未来所有轮次状态演化和动作选择的期望, γ 为折扣因子。最优化该 Q 值的最佳响应策略 π_0^* 表示为:

$$\pi_0^* = \arg \max_{\pi_0} Q_0(o_0(t), a_0(t)) \quad (30)$$

同理, 给定移动用户 n 的局部观测 $o_n(t)$ 和动作 $a_n(t)$, 用户 n 的 Q 函数定义为:

$$Q_n(o_n(t), a_n(t)) = \max_{\pi_n} \mathbb{E} \left[\sum_{\nu=t}^T \gamma^{\nu-t} r_n(\nu) | o_n(t), a_n(t) \right] \quad (31)$$

用户 n 的最佳响应策略 π_n^* 则表示为:

$$\pi_n^* = \arg \max_{\pi_n} Q_n(o_n(t), a_n(t)) \quad (32)$$

针对动态环境下联合决策变量连续、系统状态随时间演化且难以获得精确解析解的问题, 本文采用 SAC 算法求解长期优化策略 [12]。与传统强化学习仅最大化期望累积回报不同, SAC 在

目标函数中引入策略熵项，以鼓励策略保持适当随机性，避免过早收敛到局部最优。其最大熵目标函数可表示为

$$J(\pi_m) = E_{a_m \sim \pi_m} \left(\sum_{\nu=t}^T \gamma^{\nu-t} (r_m(\nu) - \alpha \pi_m(a_m(\nu) | o_m(\nu))) \right) \quad (33)$$

$m \in \{0, 1, \dots, N\}$ 代表 UAV 和移动用户智能体。在最大熵强化学习框架下，第 m 个智能体对应的状态价值函数可表示为

$$V_m(o_m(t)) = E_{a_m(t) \sim \pi_m} (Q_m(o_m(t), a_m(t); \hat{\omega}_m) - \alpha \pi_m(a_m(t) | o_m(t); \psi_m)) \quad (34)$$

其中， $\hat{\omega}_m$ 表示目标 Q 网络参数， ψ_m 表示策略网络参数。由此，第 m 个智能体的时序差分目标可进一步写为

$$y_m(t) = r_m(t) + \gamma V_m(o_m(t+1)) \quad (35)$$

基于上述时序差分目标，Q 网络损失函数定义为

$$L(\omega_m) = E_{(o_m(t), a_m(t), r_m(t), o_m(t+1)) \sim D_m} \left(\frac{1}{2} (Q_m(o_m(t), a_m(t); \omega_m) - y_m(t))^2 \right) \quad (36)$$

其中， ω_m 表示第 m 个智能体在线 Q 网络的参数， D_m 表示其经验回放池。策略网络损失函数可以表示为

$$L(\psi_m) = E_{o_m(t) \sim D_m, a_m(t) \sim \pi_m} (\alpha \pi_m(a_m(t) | o_m(t); \psi_m) - Q_m(o_m(t), a_m(t); \omega_m)) \quad (37)$$

该损失函数表明，策略网络在更新过程中不仅倾向于选择具有较高动作价值的行为，同时在熵项作用下保持适当的随机性，从而在探索与利用之间取得平衡。基于上述损失函数，第 m 个智能体的在线 Q 网络参数和目标 Q 网络可通过梯度下降方式更新为

$$\omega_m \leftarrow \omega_m - \eta_Q \nabla_{\omega_m} L(\omega_m), \quad (38)$$

$$\hat{\omega}_m \leftarrow \rho \omega_m + (1 - \rho) \hat{\omega}_m, \quad (39)$$

其中， η_Q 表示 Q 网络的学习率。目标 Q 网络参数 $\hat{\omega}_m$ 采用软更新方式迭代。类似地，策略网络参数 ψ_m 通过最小化策略损失函数进行更新，即

$$\psi_m \leftarrow \psi_m - \eta_\pi \nabla_{\psi_m} L(\psi_m) \quad (40)$$

其中， η_π 表示策略网络的学习率。为了使策略熵在训练过程中能够自动调节，SAC 通常采用温度参数 α_m 的自适应更新机制。设目标熵为 H_m ，则对应的损失函数可写为

$$L(\alpha_m) = E_{o_m(t) \sim D_m, a_m(t) \sim \pi_m} (-\alpha_m \pi_m(a_m(t) | o_m(t); \psi_m) - \alpha_m H_m) \quad (41)$$

对于温度参数 α_m ，其更新方式为

$$\alpha_m \leftarrow \alpha_m - \eta_\alpha \nabla_{\alpha_m} L(\alpha_m), \quad (42)$$

其中， η_α 表示温度参数的学习率。

4.3 基于长期外部性的支付规则

为刻画用户 n 对其余参与者造成的跨期外部性, 本文借鉴动态枢轴机制的外部性定价思想构造长期外部性支付规则 [7]。给定 UAV 动作 $a_0(t)$, 用户 k 在时隙 t 的当期价值定义为

$$v_k(a_0(t); \theta_k(t)) = -\theta_k(t)\tau_k(a_0(t)), \quad k \in N. \quad (43)$$

UAV 的当期价值为 $v_0(a_0(t)) = -\beta E_0(a_0(t))$ 。记 $\theta^{-n}(t) = \{\theta_k(t)\}_{k \in N \setminus \{n\}}$ 为剩余用户的类型向量, 则反事实环境中的即时社会福利为

$$W^{-n}(a_0(t); \theta^{-n}(t)) = v_0(a_0(t)) + \sum_{k \in N \setminus \{n\}} v_k(a_0(t); \theta_k(t)). \quad (44)$$

从下一时隙起的期望长期社会福利定义为

$$\mathcal{W}^{-n}(t+1 | a_0(t)) = \mathbb{E} \left[\sum_{\nu=t+1}^T \gamma^{\nu-(t+1)} W^{-n}(a_0(\nu); \theta^{-n}(\nu)) | a_0(t) \right]. \quad (45)$$

其中, $a_0^*(t)$ 表示完整系统的最优动作, $a_0^{*, -n}(t)$ 表示移除用户 n 后重新求得的最优动作。从 $a_0^*(t)$ 中删去用户 n 对应的任务接收决策, 所得动作记为 $\Pi_{-n}(a_0^*(t))$ 。为简洁起见, 以下以 $v_j(a)$ 表示时隙 t 内参与者 j 在动作 a 下的当期价值。则用户 n 的长期外部性支付为

$$\begin{aligned} p_n(t) = & \sum_{j \in I \setminus \{n\}} \left[v_j(a_0^{*, -n}(t)) - v_j(\Pi_{-n}(a_0^*(t))) \right] \\ & + \gamma \left[\mathcal{W}^{-n}(t+1 | a_0^{*, -n}(t)) - \mathcal{W}^{-n}(t+1 | \Pi_{-n}(a_0^*(t))) \right]. \end{aligned} \quad (46)$$

上式第一项度量用户 n 对其余参与者当期价值的影响, 第二项刻画该影响对后续系统演化的延续。为避免显式求解延续社会福利, 本文在反事实环境中以 $W^{-n}(a_0(t); \theta^{-n}(t))$ 作为 UAV 的奖励, 即 $r_0^{-n}(t) = W^{-n}(a_0(t); \theta^{-n}(t))$, 并学习相应的长期 Q 函数:

$$Q_0^{-n}(o_0^{-n}(t), a_0^{-n}(t)) = \mathbb{E} \left[\sum_{\nu=t}^T \gamma^{\nu-t} W^{-n}(a_0^{-n}(\nu); \theta^{-n}(\nu)) | o_0^{-n}(t), a_0^{-n}(t) \right]. \quad (47)$$

其中, 反事实环境中的最优动作满足

$$a_0^{*, -n}(t) = \arg \max_{a_0^{-n}(t)} Q_0^{-n}(o_0^{-n}(t), a_0^{-n}(t)). \quad (48)$$

因此, 上述长期外部性支付可等价地形式化为两个反事实长期 Q 值之差:

$$p_n(t) = Q_0^{-n}(o_0^{-n}(t), a_0^{*, -n}(t)) - Q_0^{-n}(o_0^{-n}(t), \Pi_{-n}(a_0^*(t))). \quad (49)$$

为避免在每个训练时隙为全部 N 个用户分别构造反事实分支并进行多次环境交互, 本文采用逐时隙随机抽取一个反事实分支的方式学习反事实 Q 函数。具体而言, 算法以 ϵ -贪婪规则采样反事实索引: 以 $1 - \epsilon$ 的概率取 $\kappa = 0$ 并执行完整环境分支; 以 ϵ 的概率从 $\{1, \dots, N\}$ 中均匀抽取 $\kappa = n$ 并执行用户 n 对应的反事实分支。经过多次训练, 各用户对应的反事实环境均能被持续采样, 从而以较低的单时隙计算开销覆盖全部反事实分支。

在完整环境分支中, 所有用户进行类型上报, UAV 基于完整上报状态选择联合动作。对于采样到的反事实分支 $\kappa = n$, 移除用户 n 并构造掩码上报状态 $o_0^{-n}(t)$; UAV 策略网络据此生成反事实联合动作 $a_0^{-n}(t)$ 。完整环境的转移分别写入 UAV 和各用户的经验回放池; 反事实分支仅将 UAV 转移 $(o_0^{-n}(t), a_0^{-n}(t), r_0^{-n}(t), o_0^{-n}(t+1))$ 写入 UAV 回放池, 用于学习移除用户 n 后剩余系统的长期社会福利。对于任一用户, 反事实 Q 函数表示该用户被移除后剩余系统的期望折扣累计社会福利。其最优反事实 Q 值计算为

$$Q_0^{-n,*}(t) = \max_{a_0^{-n}(t)} Q_0^{-n}(o_0^{-n}(t), a_0^{-n}(t)). \quad (50)$$

再从完整系统的最优动作中删去用户 n 对应的任务接收决策, 得到 $\Pi_{-n}(a_0^*(t))$, 并代入式 (49) 计算支付。

图 1 展示了所提方法中在线机制交互、长期外部性支付与多智能体 SAC 更新之间的关系。




图 1: 基于长期外部性支付的多智能体 SAC 框架。实线表示在线决策及模块内执行流程, 虚线表示网络更新和反事实价值传递。

算法 1 长期外部性感知多智能体 SAC 训练流程**Require:** 用户策略与双 Q 网络 $\{\pi_n, Q_n, \hat{Q}_n\}_{n \in N}$, UAV 策略与双 Q 网络 $\pi_0, Q_0, \hat{Q}_0$, 回放池 $\{\mathcal{B}_m\}_{m=0}^N$ **Ensure:** 更新后的策略参数、Q 网络参数及目标 Q 网络参数

```

1: for 每个训练回合  $e = 1, \dots, E$  do
2:   重置环境, 获得初始全局状态  $s(0)$ 、UAV 观测  $o_0(0)$  和用户观测  $\{o_n(0)\}_{n \in N}$ 。
3:   for 每个时隙  $t = 0, \dots, T - 1$  do
4:     采样分支索引  $\kappa(t)$ : 以  $1 - \epsilon$  的概率令  $\kappa(t) = 0$ ; 否则从  $N$  中均匀采样  $\kappa(t) = n$ 。
5:     用户并行生成上报  $a_n(t) = \hat{\theta}_n(t) \sim \pi_n(\cdot | o_n(t))$ ,  $\forall n \in N$ 。
6:     根据  $s(t)$  与  $\hat{\theta}(t) = \{\hat{\theta}_n(t)\}_{n \in N}$  构造完整 UAV 观测  $o_0(t)$ 。
7:     if  $\kappa(t) = 0$  then
8:       采样联合动作  $a_0(t) \sim \pi_0(\cdot | o_0(t))$ ; 执行环境, 获得  $\{\tau_n(t)\}_{n \in N}$ 、 $E_0(t)$  及下一观测。
9:       for all  $n \in N$  do
10:        由式 (49) 计算  $p_n(t)$  与  $r_n(t)$ , 存储用户转移  $(o_n(t), a_n(t), r_n(t), o_n(t+1))$  至  $\mathcal{B}_n$ 。
11:       end for
12:       令  $r_0(t) = W(t)$ , 存储完整 UAV 转移  $(o_0(t), a_0(t), r_0(t), o_0(t+1))$  至  $\mathcal{B}_0$ 。
13:     else
14:       令  $n = \kappa(t)$ , 构造  $o_0^{-n}(t)$ , 采样  $a_0^{-n}(t)$  并执行反事实环境。
15:       令  $r_0^{-n}(t) = W^{-n}(a_0^{-n}(t); \theta^{-n}(t))$ , 存储  $(o_0^{-n}(t), a_0^{-n}(t), r_0^{-n}(t), o_0^{-n}(t+1))$  至  $\mathcal{B}_0$ 。
16:     end if
17:     for all  $m \in \{0\} \cup N$  且  $|\mathcal{B}_m| \geq B$  do
18:       从  $\mathcal{B}_m$  采样小批量  $\mathcal{D}_m(t) = \{(o_m(\tau), a_m(\tau), r_m(\tau), o_m(\tau+1))\}$ 。
19:       由  $y_m(\tau) = r_m(\tau) + \gamma V_m(o_m(\tau+1))$  更新  $\omega_m(t+1)$ 、 $\psi_m(t+1)$ 、 $\alpha_m(t+1)$  与  $\hat{\omega}_m(t+1)$ 。
20:     end for
21:   end for
22: end for

```

5 仿真结果与分析 (Simulation Results and Analysis)

5.1 仿真设置

本文在统一的离散 UAV 辅助 MEC 环境中训练并测试各比较方法, 每个训练回合包含 10 个决策时隙, 即 $T = 10$ 。在每个训练回合开始时独立生成用户类型; 各时隙中的任务规模独立采样, 从而刻画任务到达的随机性与用户间的资源竞争。

系统包含一架 UAV 和三名移动用户, 用户数记为 $M = 3$ 。

用户的真实时延敏感系数 θ_n 从集合 $\{0.2, 0.5, 0.8\}$ 中独立均匀采样。各时隙中, 任务规模 $D_n(t)$ 从集合 $\{100, 200, 300\}$ KB 中独立均匀采样。每比特所需 CPU 周期数设为 $\xi = 1000$, UAV 与本地设备的 CPU 频率分别设为 $F_{\text{uav}} = 0.1$ GHz 和 $f_{\text{loc}} = 1.5$ GHz。

物理场景设置为 $1\text{ km} \times 1\text{ km}$ 的服务区域, UAV 飞行高度和速度分别为 100 m 与 30 m/s。上行通信带宽为 0.2 MHz, 用户发射功率为 10 dBm, 噪声功率为 -80 dBm。LoS 概率参数取 $\mu_1 = 11.5$ 、 $\mu_2 = 0.1$; LoS/NLoS 参考路径损耗分别取 -3 dB 和 -20 dB, 路径损耗指数分别取 2 和 3.5。

各智能体均采用离散动作 SAC 进行训练, 策略网络与双 Q 网络均采用两层全连接网络, 并以修正线性单元 (rectified linear unit, ReLU) 作为激活函数。折扣因子设为 $\gamma = 0.99$, 学习率设为 3×10^{-4} , 初始温度参数为 0.2。UAV 与用户网络的隐藏层宽度分别为 128 和 64。UAV 的目标网络在每次参数更新后以 $\tau = 0.005$ 进行软更新, 用户目标网络的更新间隔设为 10。各智能体经验回放池容量均设为 250000, 小批量大小为 128。温度参数通过最大熵目标自适应调节, UAV 与用户的目标熵系数分别设为 -0.2 和 -0.005 。所有实验采用随机种子 42; 图 2 给出了覆盖 2.5×10^6 个训练回合的回报演化过程。

5.2 对比方法与评价协议

即时 VCG 定价基线: 该方法仍采用多智能体 SAC 学习用户上报策略与 UAV 卸载决策策略。在定价阶段, 依据某用户参与所造成的当前时隙社会福利外部性确定其支付, 即以该用户参与前后其余用户福利的变化衡量其支付成本。该基线保留联合学习与即时外部性定价过程, 用于对比所提机制在支付设计上的改进。

无定价基线: 该方法保留用户上报和 UAV 卸载决策过程, 用户与 UAV 均通过 SAC 学习相应策略, 但不设置任何支付规则。用户效用仅与任务完成时延相关, 因而其上报与卸载决策不受经济支付的直接影响。该基线用于刻画不引入定价机制时系统的性能。

5.3 结果分析




图 2: 所提方法与两类基线的 UAV 训练回报。

图 2 给出了三种方法的 UAV 训练回报演化。所提方法在初始探索阶段后迅速达到稳定区间, 且在后续训练中始终保持最高的平均回报。相比之下, 即时 VCG 定价基线虽能利用即时外

部性改善资源分配，但其反事实价值评估较为局部，稳定回报仍低于所提方法；无定价基线的回报最低且波动更为显著。这表明，支付机制不仅影响用户的上报动机，也能通过反事实价值定价改善 UAV 对用户类型的识别与卸载决策。






图 3: 不同真实时延敏感系数和上报敏感系数下的平均用户效用。

图 3刻画了真实类型与上报类型对平均用户效用的共同影响。总体而言，用户效用随真实时延敏感系数提高而增大，表明资源分配能够优先服务于对时延更敏感的任务。对于低敏感用户 ($\theta = 0.2$)，如实上报取得最高效用 0.060，而提高上报仅带来效用下降。对于中、高敏感用户，相邻上报水平之间的效用差异较小，最大偏离收益分别仅为 0.005 和 0.005。因此，所提机制能够显著抑制虚报动机，并呈现近似激励相容性。



(a) 平均绝对上报误差的训练演化。



(b) 各用户及总体平均绝对上报误差。

图 4: 所提方法与即时 VCG 定价基线下的用户上报偏差。

图 4(a) 给出了平均绝对上报误差随训练过程的变化。经过初始探索后, 所提方法的误差稳定在较低区间, 且整体低于即时 VCG 定价基线, 表明反事实价值定价能够持续抑制策略性虚报。图 4(b) 进一步给出分用户比较: 所提方法在三个用户上的平均绝对上报误差分别为 0.165、0.113 和 0.100, 均低于即时 VCG 定价基线对应的 0.199、0.204 和 0.154。从总体指标看, 所提方法将平均绝对上报误差由 0.185 降至 0.126, 说明其能够更有效地将用户收益与真实类型对齐。

6 参考文献 (References)

- [1] Bo Shen, Qi Gu, and Gang Yang. Joint task offloading and UAVs deployment for UAV-assisted mobile edge computing. *Computer Networks*, 234:109943, 2023.
- [2] Min Hui, Jian Chen, Long Yang, Lu Lv, Hai Jiang, and Naofal Al-Dhahir. UAV-assisted mobile edge computing: Optimal design of UAV altitude and task offloading. *IEEE Transactions on Wireless Communications*, 23(10):13633–13647, 2024.
- [3] Tong Wang and Chuanchuan You. Distributed user association and computation offloading in UAV-assisted mobile edge computing systems. *IEEE Access*, 12:63548–63567, 2024.
- [4] J. Xiao, Q. Gao, and Z. Yang. Multi-round auction-based resource allocation for edge computing: Maximizing social welfare. *Future Generation Computer Systems*, 140:365–375, 2023.
- [5] Yi Su, Wenhao Fan, Yuan'an Liu, and Fan Wu. A truthful combinatorial auction mechanism towards mobile edge computing in industrial internet of things. *IEEE Transactions on Cloud Computing*, 11(2):1678–1691, 2022.
- [6] Leijie Wu, Song Guo, Zicong Hong, Yi Liu, Wenchao Xu, and Yufeng Zhan. Long-term adaptive VCG auction mechanism for sustainable federated learning with periodical client shifting. *IEEE Transactions on Mobile Computing*, 23(5):6060–6074, 2024.
- [7] Dirk Bergemann and Juuso Välimäki. The dynamic pivot mechanism. *Econometrica*, 78(2):771–789, 2010.
- [8] Akram Al-Hourani, Sithamparanathan Kandeepan, and Abbas Jamalipour. Modeling air-to-ground path loss for low altitude platforms in urban environments. In *2014 IEEE Global Communications Conference*, pages 2898–2904. IEEE, 2014.
- [9] Changsheng You, Kaibin Huang, Hyukjin Chae, and B.-H. Kim. Energy-efficient resource allocation for mobile-edge computation offloading. *IEEE Transactions on Wireless Communications*, 16(3):1397–1411, 2017.
- [10] Yuyi Mao, Jun Zhang, and Khaled B. Letaief. Dynamic computation offloading for mobile-edge computing with energy harvesting devices. *IEEE Journal on Selected Areas in Communications*, 34(12):3590–3605, 2016.
- [11] Edward H. Clarke. Multipart pricing of public goods. *Public Choice*, 11(1):17–33, 1971.
- [12] Tuomas Haarnoja, Aurick Zhou, Pieter Abbeel, and Sergey Levine. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In *Proceedings of the 35th International Conference on Machine Learning*, volume 80 of *Proceedings of Machine Learning Research*, pages 1861–1870. PMLR, 2018.