面向长期外部性的无人机辅助任务卸载动态激励机制

李锡泽

摘要

在无人机（UAV）辅助移动边缘计算（MEC）网络中，UAV 为地面用户提供计算卸载服务。受机载资源限制，UAV 难以同时满足多个用户的需求，可能出现拥塞、时延增加和资源利用率下降等问题。为协调 UAV 与用户之间的资源交易，本文构建部分可观测条件下的多智能体序贯决策模型，将策略性类型报告、任务分配和动态支付纳入统一框架。用户根据私有时延敏感类型选择报告值，UAV 在观察用户报告后决定任务接收和服务位置。用户以最大化自身长期效用为目标，UAV 以最大化系统长期社会福利为目标。针对用户策略性虚报可能造成的资源错配，本文提出一种动态 VCG 式定价机制，并采用离散动作 SAC 分别学习 UAV 的控制策略和用户的报告策略。定价时，UAV 以用户缺席的剩余系统为参照，利用学得的长期动作价值函数，估计重新优化决策与沿用原系统决策时其余参与者的长期福利差额，并据此确定该用户的支付。原有实验结果显示，相较于即时 VCG 定价和无定价基线，所提机制能够提高长期资源配置效率并抑制策略性虚报。修订后的模型仍需重新训练和验证。

关键词：无人机辅助移动边缘计算、动态激励机制、多智能体强化学习

1 引言（Introduction）

在无人机（UAV）辅助移动边缘计算（MEC）网络中，UAV 可作为空中边缘服务器，通过灵活调整服务位置为地面用户提供任务卸载服务 [1–3]。UAV 的机载计算资源有限，提供服务还需承担飞行、通信和计算成本，因此需要在多个用户之间合理分配资源。由于 UAV 无法直接获知用户的私有信息，用户可能为提高自身收益而虚报，进而导致资源错配。因此，有必要设计能够激励用户如实报告并提高资源配置效率的定价机制。

拍卖机制为 MEC 中多个用户竞争有限计算资源提供了分配与定价方法。在 UAV 辅助任务卸载场景中，Wang 等 [4] 采用逐轮第二价格拍卖，由用户竞价决定服务对象，并以次高报价确定支付。Habiba 等 [5] 在多接入边缘计算中采用重复拍卖，依据任务到达和服务器负载，通过改进的广义第二价格规则逐轮分配资源并确定支付。这类方法能够根据竞价和系统状态调整当前轮次的资源分配，但在多个任务竞争有限资源时，还需衡量单个用户获得服务对其他参与者福利的影响。VCG 机制将标准单物品第二价格拍卖的定价思想推广到更一般的配置问题，依据这种外部性确定支付。Ren 等 [6] 在车联网边缘计算的依赖任务卸载中采用 VCG 支付，以兼顾配置效率与真实报告。然而，在 UAV 辅助 MEC 的动态卸载中，本轮接收任务和调整服务位置会影响其他用户后续的服务机会与时延，进而改变系统的长期福利。若支付仅依据当期福利确定，用户造成的跨时隙外部性便无法得到充分反映，可能削弱如实报告激励并降低长期资源配置效率。

针对上述问题，本文借鉴动态枢轴机制的长期外部性定价思想 [7]，面向任务动态到达、UAV 服务位置随时间变化且机载资源受限的场景，提出一种动态 VCG 式激励机制。该机制中，UAV 以最大化长期社会福利为目标确定任务接收和服务位置，用户以最大化自身长期效用为目标选择类型报告。UAV 和各用户分别采用离散动作 SAC 学习相应策略。定价时，UAV 利用学得的长期动作价值函数，估计用户缺席后重新优化决策与沿用完整系统决策时其余参与者的长期折扣福利，并以两者之差确定该用户的外部性支付。训练过程中，算法随机采样完整系统分支或用户缺席的反事实分支，以降低长期价值评估所需的环境交互开销。

2 系统模型（System Model）

考虑由一架 UAV 和移动用户集合 $N = \{1, 2, \ldots, N\}$ 组成的 UAV 辅助 MEC 系统，其中节点 0 表示 UAV，节点 $n \in N$ 表示第 n 个移动用户。系统在离散时隙中运行。在每个时隙内，UAV 基于当前系统状态联合确定目标服务位置和任务接收结果。被接收的任务经上行链路传输后由 UAV 处理，其余任务在本地完成。下文依次建立通信、计算卸载和 UAV 能耗模型。

2.1 通信模型

考虑用户 n 在时隙 t 向 UAV 上传卸载任务。UAV 与用户 n 之间的上行链路可能为视距（LoS）或非视距（NLoS）链路，其中 LoS 链路的概率表示为：

$$Pr_{n,LoS}\left(t\right) = \frac{1}{1 + \mu_1 e^{-\mu_2(\phi_n(t) - \mu_1)}} \tag{1}$$

其中，μ_1 和 μ_2 为环境常数，$\phi_n\left(t\right)$ 表示 UAV 与用户 n 之间的仰角，其定义为：

$$\phi_n(t) = \arcsin\left(\frac{z_{0,n}(t)}{\left(l_0\left(t\right) - l_n\left(t\right)\right)}\right) \tag{2}$$

式中，$z_{0,n}(t)$ 为 UAV 与用户 n 之间的高度差，$l_0\left(t\right)$ 和 $l_n\left(t\right)$ 分别表示 UAV 和用户 n 的位置。相应地，NLoS 链路的概率由 LoS 概率的补集给出 [8]：

$$Pr_{n,NLoS}\left(t\right) = 1 - Pr_{n,LoS}\left(t\right) \tag{3}$$

在给定传播状态 ν 下，UAV 与用户 n 之间的路径损耗建模为

$$\chi_{0,n}\left(t\right) = \eta_\nu \left(l_0\left(t\right) - l_n\left(t\right)\right)_2^{-\alpha_\nu}, \nu \in \{\text{LoS}, \text{NLoS}\} \tag{4}$$

其中，η_ν 为参考路径损耗常数，α_ν 为路径损耗指数。为刻画小尺度衰落，假设信道衰落系数服从 Nakagami-m 分布，即

$$h_{0,n}\left(t\right) \sim \text{Nakagami}\left(m_\nu\right), \nu \in \{\text{LoS}, \text{NLoS}\} \tag{5}$$

由路径损耗和小尺度衰落共同决定的信道增益为

$$g_{0,n}\left(t\right) = \left(h_{0,n}\left(t\right)\right)^2 \chi_{0,n}\left(t\right) \tag{6}$$

据此，用户 n 向 UAV 的上行传输速率 $\rho_n(t)$ 可表示为

$$\rho_n(t) = B\left(1 + \frac{P_n g_{0,n}(t)}{\sigma^2}\right) \tag{7}$$

其中，B 为信道带宽，P_n 为用户 n 的发射功率，σ^2 为高斯噪声功率。若用户 n 在时隙 t 向 UAV 卸载的数据量为 $D_n(t)$，则对应的上传时延为

$$\tau_n^{trans}(t) = \frac{D_n(t)}{\rho_n(t)} \tag{8}$$

2.2 计算卸载模型

用户 n 在时隙 t 产生一个数据量为 $D_n(t)$ 的计算任务。设每比特数据的处理需要 ξ 个 CPU 周期，则该任务的计算量为 $L_n(t) = D_n(t)\xi$。任务可在本地执行，也可卸载至 UAV 处理 [9]。

设 UAV 的总计算能力为 F_{uav}。定义联合决策变量 $f_n(t)$ 为 UAV 分配给用户 n 的 CPU 频率：当 $f_n(t) = 0$ 时，任务在本地计算且不占用 UAV 算力。当 $f_n(t) > 0$ 时，任务卸载至 UAV，$f_n(t)$ 为分配给该任务的计算频率。计算时各频率均以 Hz 为单位。为适配离散动作 SAC，设可选的正卸载频率构成有限集合 $\mathcal{F} \subset (0, F_{\text{uav}}]$，则

$$f_n(t) \in \mathcal{F} \cup \{0\}, \qquad \sum_{n=1}^{N} f_n(t) \le F_{\text{uav}}. \tag{9}$$

频率集合的具体离散粒度由实验设置确定。联合动作仅允许选择满足总算力约束的组合。当任务卸载时，UAV 侧计算时延为 $\tau_n^{off}(t) = L_n(t)/f_n(t)$。因此，用户 n 的任务完成时延表示为

$$\tau_n(t) = \begin{cases} \tau_n^{local}(t), & f_n(t) = 0, \\ \tau_n^{trans}(t) + \dfrac{L_n(t)}{f_n(t)}, & f_n(t) \in \mathcal{F}. \end{cases} \tag{10}$$

其中，本地计算时延为

$$\tau_n^{local}(t) = \frac{D_n(t)\xi}{f_n^{local}} \tag{11}$$

式中，f_n^{local} 为用户 n 的本地 CPU 计算频率。

2.3 UAV 能耗模型

在时隙 t 内，UAV 的能耗由飞行部署、悬停服务和任务计算三部分构成。设 P^{fly} 和 P^{hov} 分别表示 UAV 的飞行功率和悬停功率。

在时隙开始时，UAV 根据轨迹规划结果从上一位置 $l_0(t-1)$ 移动至目标位置 $l_0(t)$。假设 UAV 以恒定速度 V_{uav} 飞行，则移动能耗为

$$E_{move}(t) = P^{fly} \cdot \frac{(l_0(t) - l_0(t-1))}{V_{\text{uav}}} \tag{12}$$

UAV 抵达目标位置后，为被接收任务提供通信与计算服务，其悬停能耗建模为

$$E_{hov}(t) = \sum_{n:f_n(t)>0} P^{hov}[\tau_n^{trans}(t) + \tau_n^{off}(t)] \tag{13}$$

此外，根据 CMOS 动态功耗模型，UAV 的计算能耗与分配的计算频率有关 [10]。设芯片的有效电容系数为 κ_{uav}，则 UAV 在时隙 t 处理卸载任务的计算能耗为

$$E_{comp}(t) = \sum_{n=1}^{N} \kappa_{\text{uav}} \xi D_n(t) (f_n(t))^2 \tag{14}$$

因此，UAV 在时隙 t 的总能耗为

$$E_0(t) = E_{move}(t) + E_{hov}(t) + E_{comp}(t) \tag{15}$$

上述模型共同决定用户任务时延与 UAV 能耗，并为后续参与者效用与系统社会福利的定义提供基础。

2.4 动态激励机制

为刻画 UAV 辅助 MEC 中任务接收与轨迹控制的时序耦合，本文构建基于类型报告和外部性定价的长期动态激励机制 [11]。由于 UAV 的位置随时隙演化，当前决策会影响后续服务条件与资源分配，因此需要在动态过程中联合确定资源分配与支付规则。

UAV 作为服务平台，负责分配计算资源并确定目标服务位置。移动用户作为机制参与者，通过类型报告参与 UAV 计算资源分配。用户 n 在时隙 t 的私有类型为真实时延敏感度 $\theta_n(t) \in [0,1]$，向 UAV 提交的类型报告记为 $\hat{\theta}_n(t)$。由于用户以最大化自身效用为目标，其报告值可能偏离真实类型。

在时隙 t 开始时，系统的公共物理状态由 UAV 与各用户在上一时隙的位置，即 $l_0(t-1)$ 和 $l_n(t-1)$，以及本时隙到达的任务量 $D_n(t)$ 共同构成。用户提交上报信息后，UAV 根据当前状态和全部上报，联合确定计算决策 $f_n(t)$ 与目标服务位置 $l_0(t)$。

动作执行后，系统获得用户 n 在时隙 t 的任务完成时延 $\tau_n(t)$。据此，用户 n 的单步效用定义为准线性形式：

$$U_n(t) = -\theta_n(t)\tau_n(t) - p_n(t) \tag{16}$$

其中，$p_n(t)$ 为该用户占用计算资源所缴纳的支付费用。进一步地，定义 UAV 在时隙 t 的效用为

$$U_0(t) = \sum_{n=1}^{N} p_n(t) - \beta E_0(t) \tag{17}$$

其中，$E_0(t)$ 表示 UAV 在该时隙的总能耗，β 为能耗成本系数，用于刻画能量消耗对系统效益的影响。因此，时隙 t 的即时社会福利可定义为所有参与方效用之和，即

$$W(t) = U_0(t) + \sum_{n=1}^{N} U_n(t) = -\sum_{n=1}^{N} \theta_n(t)\tau_n(t) - \beta E_0(t) \tag{18}$$

3 问题建模（Problem Formulation）

3.1 优化问题

在动态 UAV 辅助边缘计算场景中，任务到达、用户状态与 UAV 位置均随时间演化。当前决策不仅影响即时资源配置结果，还会改变后续时隙的系统状态。因此，动态激励机制需要同

时考虑系统的长期资源配置效率和用户的个体决策激励，在优化长期社会福利的同时兼顾用户的类型报告激励与持续参与意愿。基于上述目标，本文分别从 UAV 服务平台和移动用户两个层面构建优化问题。

UAV 侧社会福利优化：作为服务平台，UAV 根据当前系统状态与用户类型报告，在各时隙联合确定计算决策和目标服务位置。为刻画当前决策对未来系统演化的影响，UAV 以期望折扣累计社会福利最大化为目标，其优化问题表述为

$$\begin{aligned} \max_{\{f_n(t)\},\{l_0(t)\}} \quad & \mathbb{E}\left[\sum_{t=0}^{T}\gamma^t W(t)\right] \\ \text{s.t.} \quad & f_n(t)\in\mathcal{F}\cup\{0\}, \quad \forall n\in N,\ \forall t, \\ & \sum_{n=1}^{N} f_n(t)\le F_{\text{uav}}, \quad \forall t, \\ & l_0(t)\in L, \qquad\qquad \forall t. \end{aligned} \tag{19}$$

其中，$\gamma\in[0,1)$ 为折扣因子，$\mathbb{E}[\cdot]$ 表示对任务到达、状态转移及策略随机性等不确定因素取期望。约束条件分别限定联合决策变量的取值、UAV 总计算能力和可选服务位置。

用户侧效用优化：移动用户作为自利的机制参与者，在给定机制规则和其他参与者策略的条件下，以最大化自身效用为目标。对于任意用户 n，其决策变量为各时隙提交的类型报告 $\hat{\theta}_n(t)$，相应的优化问题表述为

$$\begin{aligned} \max_{\{\hat{\theta}_n(t)\}} \quad & \mathbb{E}\left[\sum_{t=0}^{T}\gamma^t U_n(t)\right] \\ \text{s.t.} \quad & \hat{\theta}_n(t)\in[0,1], \qquad \forall t. \end{aligned} \tag{20}$$

用户效用 $U_n(t)$ 同时取决于任务完成时延和支付，因此，支付规则会直接影响用户的类型报告策略。综上，本文旨在联合设计任务接收、UAV 轨迹控制与支付规则，协调平台侧的长期社会福利目标和用户侧的长期效用目标，从而在兼顾用户上报激励与参与意愿的同时，提高系统的长期资源配置效率。

3.2 部分可观测条件下的多智能体序贯决策模型

本文将 UAV 辅助 MEC 中的类型报告、任务分配和支付过程描述为部分可观测条件下的多智能体序贯决策模型，并采用多智能体强化学习求解各参与方的决策策略。决策参与方包括 UAV 平台和移动用户，记为 $I=\{0\}\cup N$，其中 0 表示 UAV。各参与方依据不同的决策信息行动，且时隙内的用户报告先于 UAV 控制决策。时隙 t 的系统状态定义为

$$s(t)=\left\{l_0(t-1),\{l_n(t-1)\}_{n=1}^{N},\{D_n(t)\}_{n=1}^{N},\{\theta_n(t)\}_{n=1}^{N}\right\}. \tag{21}$$

其中，$\theta_n(t)$ 为用户 n 的私有类型，因此系统状态包含的信息不等同于 UAV 可直接获得的信息。给定当前状态和本时隙决策，系统按状态演化规律转移至下一时隙，记为

$$s(t+1)\sim P(\cdot\mid s(t),a_0(t),\{a_n(t)\}_{n\in N}), \tag{22}$$

其中，转移规律包含任务到达、位置更新及其他外生随机因素。每个时隙内，用户先根据各自可用信息并行提交类型报告。随后，UAV 观察全部报告并选择计算资源分配和目标服务位置。环境执行任务并计算时延、支付及各方回报，之后系统进入下一状态。

3.2.1 UAV 智能体

UAV 在时隙 t 的决策信息由公开物理状态和用户提交的报告构成：

$$o_0(t) = \left\{ l_0(t-1), \{l_n(t-1)\}_{n=1}^{N}, \{D_n(t)\}_{n=1}^{N}, \{\hat{\theta}_n(t)\}_{n=1}^{N} \right\}. \tag{23}$$

其动作为计算决策与目标服务位置构成的联合控制动作，且计算决策须满足式 (9)：

$$a_0(t) = \left(\{f_n(t)\}_{n=1}^{N}, l_0(t) \right). \tag{24}$$

UAV 的策略记为 $\pi_0(a_0 \mid o_0)$，表示在给定观测 o_0 时选择可行联合动作 a_0 的概率。UAV 的即时奖励取为系统即时社会福利：

$$r_0(t) = W(t) \tag{25}$$

3.2.2 移动用户智能体

第 n 个移动用户在时隙 t 可获得自身类型、任务量及位置等信息，其决策信息为

$$o_n(t) = \{l_n(t-1), l_0(t-1), D_n(t), \theta_n(t)\}. \tag{26}$$

任务量 $D_n(t)$ 和真实时延敏感度 $\theta_n(t)$ 使用户能够根据信息状态调整上报策略。用户的动作为向 UAV 提交的时延敏感度上报：

$$a_n(t) = \hat{\theta}_n(t). \tag{27}$$

用户 n 的策略记为 $\pi_n(a_n \mid o_n)$，表示在给定观测 o_n 时选择类型报告 a_n 的概率。用户 n 的即时回报定义为其单时隙效用：

$$r_n(t) = U_n(t). \tag{28}$$

用户报告是用户策略的输出，真实类型仅供用户自身形成决策信息。UAV 的策略输入包含报告而不包含真实类型。仿真环境使用真实类型计算社会福利回报，该回报不作为 UAV 策略的直接输入。将各参与方的策略组合记为 $\boldsymbol{\pi} = (\pi_0, \pi_1, \ldots, \pi_N)$。给定当前观测和动作，策略组合下的长期动作价值定义为

$$Q_m^{\boldsymbol{\pi}}(o_m(t), a_m(t)) = \mathbb{E}_{\boldsymbol{\pi}} \left[\sum_{\nu=t}^{T} \gamma^{\nu-t} r_m(\nu) \mid o_m(t), a_m(t) \right], \quad m \in I. \tag{29}$$

其中，$r_0(t) = W(t)$，而 $r_n(t) = U_n(t)$。策略网络依据自身决策信息生成动作，动作价值用于评价该动作在当前策略组合下带来的长期回报。训练过程中，各策略通过多智能体 SAC 迭代更新。

4 算法设计（Algorithm Design）

4.1 基于 SAC 的策略学习

针对动态环境下联合动作组合较多、系统状态随时间演化且难以获得精确解析解的问题，本文采用离散动作 SAC 算法 [12]。与传统强化学习仅最大化期望累积回报不同，SAC 在目标函数中引入策略熵项，以鼓励策略保持适当随机性，避免过早收敛到局部最优。其最大熵目标函数可表示为

$$J(\pi_m) = E_{a_m \sim \pi_m}\left(\sum_{\nu=t}^{T} \gamma^{\nu-t}\left(r_m(\nu) - \alpha \log \pi_m\left(a_m(\nu) \mid o_m(\nu)\right)\right)\right) \tag{30}$$

$m \in \{0, 1, \ldots, N\}$ 代表 UAV 和移动用户智能体。在最大熵强化学习框架下，第 m 个智能体对应的状态价值函数可表示为

$$V_m(o_m(t)) = E_{a_m(t)\sim\pi_m}\left(Q_m(o_m(t), a_m(t), \hat{\omega}_m) - \alpha \log \pi_m\left(a_m(t) \mid o_m(t), \psi_m\right)\right) \tag{31}$$

其中，$\hat{\omega}_m$ 表示目标 Q 网络参数，ψ_m 表示策略网络参数。由此，第 m 个智能体的时序差分目标可进一步写为

$$y_m(t) = r_m(t) + \gamma V_m(o_m(t+1)) \tag{32}$$

基于上述时序差分目标，Q 网络损失函数定义为

$$L(\omega_m) = E_{(o_m(t), a_m(t), r_m(t), o_m(t+1))\sim D_m}\left(\frac{1}{2}\left(Q_m(o_m(t), a_m(t), \omega_m) - y_m(t)\right)^2\right) \tag{33}$$

其中，ω_m 表示第 m 个智能体在线 Q 网络的参数，D_m 表示其经验回放池。策略网络损失函数可以表示为

$$L(\psi_m) = E_{o_m(t)\sim D_m, a_m(t)\sim\pi_m}\left(\alpha \log \pi_m\left(a_m(t) \mid o_m(t), \psi_m\right) - Q_m(o_m(t), a_m(t), \omega_m)\right) \tag{34}$$

该损失函数使策略网络倾向于选择动作价值较高的行为，同时通过熵项保持适当的随机性，从而平衡探索与利用。基于上述损失函数，第 m 个智能体的在线 Q 网络参数和目标 Q 网络可通过梯度下降方式更新为

$$\omega_m \leftarrow \omega_m - \eta_Q \nabla_{\omega_m} L(\omega_m), \tag{35}$$

$$\hat{\omega}_m \leftarrow \rho \omega_m + (1-\rho)\hat{\omega}_m, \tag{36}$$

其中，η_Q 表示 Q 网络的学习率，目标 Q 网络参数 $\hat{\omega}_m$ 通过软更新迭代。类似地，策略网络参数 ψ_m 通过最小化策略损失函数进行更新，即

$$\psi_m \leftarrow \psi_m - \eta_\pi \nabla_{\psi_m} L(\psi_m) \tag{37}$$

其中，η_π 表示策略网络的学习率。为了使策略熵在训练过程中能够自动调节，SAC 通常采用温度参数 α_m 的自适应更新机制。设目标熵为 H_m，则对应的损失函数可写为

$$L(\alpha_m) = E_{o_m(t)\sim D_m, a_m(t)\sim\pi_m}\left(-\alpha_m \pi_m\left(a_m(t) \mid o_m(t), \psi_m\right) - \alpha_m H_m\right) \tag{38}$$

对于温度参数 α_m，其更新方式为

$$\alpha_m \leftarrow \alpha_m - \eta_\alpha \nabla_{\alpha_m} L(\alpha_m), \tag{39}$$

其中，η_α 表示温度参数的学习率。

4.2 基于长期外部性的支付规则

为刻画用户 n 对其余参与者造成的跨期外部性，本文借鉴动态枢轴机制的外部性定价思想构造长期外部性支付规则 [7]。给定 UAV 动作 $a_0(t)$，用户 k 在时隙 t 的当期价值定义为

$$v_k(a_0(t),\theta_k(t)) = -\theta_k(t)\tau_k(a_0(t)), \qquad k \in N. \tag{40}$$

UAV 的当期价值为 $v_0(a_0(t)) = -\beta E_0(a_0(t))$。记 $\boldsymbol{\theta}^{-n}(t) = \{\theta_k(t)\}_{k\in N\setminus\{n\}}$ 为剩余用户的类型向量，则反事实环境中的即时社会福利为

$$W^{-n}(a_0(t),\boldsymbol{\theta}^{-n}(t)) = v_0(a_0(t)) + \sum_{k\in N\setminus\{n\}} v_k(a_0(t),\theta_k(t)). \tag{41}$$

从下一时隙起的期望长期社会福利定义为

$$\mathcal{W}^{-n}(t+1 \mid a_0(t)) = \mathbb{E}\left[\sum_{\nu=t+1}^{T} \gamma^{\nu-(t+1)} W^{-n}(a_0(\nu),\boldsymbol{\theta}^{-n}(\nu)) \mid a_0(t)\right]. \tag{42}$$

其中，$a_0^*(t)$ 表示完整系统的最优动作，$a_0^{*,-n}(t)$ 表示移除用户 n 后重新求得的最优动作。从 $a_0^*(t)$ 中删去用户 n 对应的计算决策 $f_n(t)$，保留其他用户的决策与服务位置，所得动作记为 $\Pi_{-n}(a_0^*(t))$。移除用户后其占用的算力被释放，不重新分配，因此该动作仍满足总算力约束。为简洁起见，以下以 $v_j(a)$ 表示时隙 t 内参与者 j 在动作 a 下的当期价值。则用户 n 的长期外部性支付为

$$\begin{aligned} p_n(t) = &\sum_{j\in I\setminus\{n\}} \left[v_j(a_0^{*,-n}(t)) - v_j(\Pi_{-n}(a_0^*(t)))\right] \\ &+ \gamma\left[\mathcal{W}^{-n}(t+1 \mid a_0^{*,-n}(t)) - \mathcal{W}^{-n}(t+1 \mid \Pi_{-n}(a_0^*(t)))\right]. \end{aligned} \tag{43}$$

上式第一项度量用户 n 对其余参与者当期价值的影响，第二项刻画该影响对后续系统演化的延续。为避免显式求解延续社会福利，本文在反事实环境中以 $W^{-n}(a_0(t),\boldsymbol{\theta}^{-n}(t))$ 作为 UAV 的奖励，即 $r_0^{-n}(t) = W^{-n}(a_0(t),\boldsymbol{\theta}^{-n}(t))$，并学习相应的长期 Q 函数：

$$Q_0^{-n}(o_0^{-n}(t),a_0^{-n}(t)) = \mathbb{E}\left[\sum_{\nu=t}^{T} \gamma^{\nu-t} W^{-n}(a_0^{-n}(\nu),\boldsymbol{\theta}^{-n}(\nu)) \mid o_0^{-n}(t),a_0^{-n}(t)\right]. \tag{44}$$

其中，反事实环境中的最优动作满足

$$a_0^{*,-n}(t) = \arg\max_{a_0^{-n}(t)} Q_0^{-n}(o_0^{-n}(t),a_0^{-n}(t)). \tag{45}$$

因此，上述长期外部性支付可等价地形式化为两个反事实长期 Q 值之差：

$$p_n(t) = Q_0^{-n}(o_0^{-n}(t),a_0^{*,-n}(t)) - Q_0^{-n}(o_0^{-n}(t),\Pi_{-n}(a_0^*(t))). \tag{46}$$

为降低每个训练时隙的环境交互开销，本文通过随机采样分支学习反事实 Q 函数。具体而言，算法按照 ϵ-贪婪规则采样分支索引，以 $1-\epsilon$ 的概率取 $\kappa = 0$ 并执行完整环境分支，以 ϵ 的概率从 $\{1,\dots,N\}$ 中均匀抽取 $\kappa = n$ 并执行用户 n 对应的反事实分支。经过多次训练，各用户对应的反事实环境均可得到采样，从而以较低的单时隙计算开销覆盖全部反事实分支。

在完整环境分支中，所有用户进行类型上报，UAV 基于完整上报状态选择联合动作。对于采样到的反事实分支 $\kappa = n$，移除用户 n 并构造掩码上报状态 $o_0^{-n}(t)$。UAV 策略网络据此生成反事实联合动作 $a_0^{-n}(t)$。完整环境的转移分别写入 UAV 和各用户的经验回放池。反事实分支仅将 UAV 转移 $(o_0^{-n}(t), a_0^{-n}(t), r_0^{-n}(t), o_0^{-n}(t+1))$ 写入 UAV 回放池，用于学习移除用户 n 后剩余系统的长期社会福利。对于任一用户，反事实 Q 函数表示该用户被移除后剩余系统的期望折扣累计社会福利。其最优反事实 Q 值计算为

$$Q_0^{-n,*}(t) = \max_{a_0^{-n}(t)} Q_0^{-n}(o_0^{-n}(t), a_0^{-n}(t)). \tag{47}$$

再从完整系统的最优动作中删去用户 n 对应的计算决策，得到 $\Pi_{-n}(a_0^*(t))$，并代入式 (46) 计算支付。

图 1 展示了所提方法中在线机制交互、长期外部性支付与多智能体 SAC 更新之间的关系。

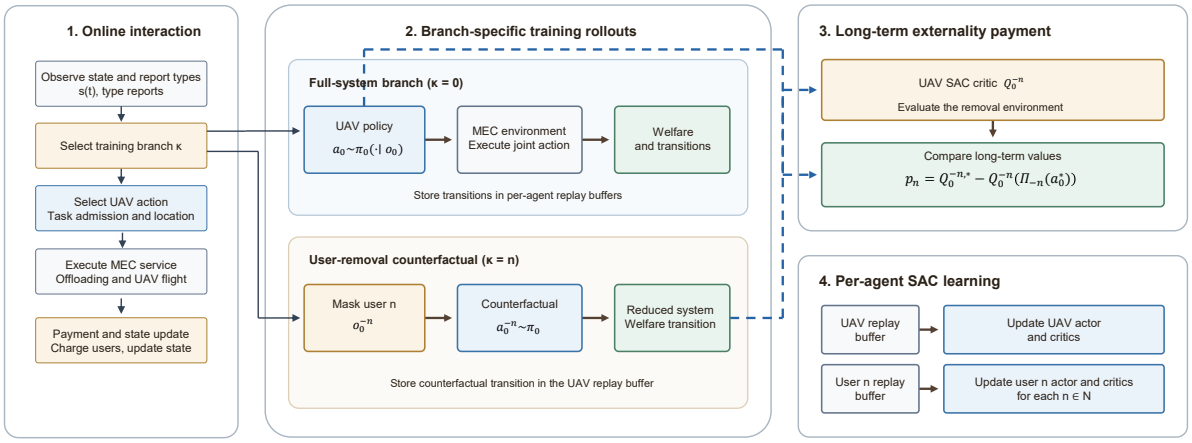


图 1: 基于长期外部性支付的多智能体 SAC 框架。实线表示在线决策及模块内执行流程，虚线表示网络更新和反事实价值传递。

算法 1 长期外部性感知多智能体 SAC 训练流程

Require: 用户策略与双 Q 网络 $\{\pi_n, Q_n, \hat{Q}_n\}_{n\in N}$，UAV 策略与双 Q 网络 $\pi_0, Q_0, \hat{Q}_0$，回放池 $\{\mathcal{B}_m\}_{m=0}^{N}$
Ensure: 更新后的策略参数、Q 网络参数及目标 Q 网络参数

for 每个训练回合 $e = 1, \ldots, E$ **do**
  重置环境，获得初始全局状态 $s(0)$、UAV 观测 $o_0(0)$ 和用户观测 $\{o_n(0)\}_{n\in N}$。
  for 每个时隙 $t = 0, \ldots, T-1$ **do**
    采样分支索引 $\kappa(t)$：以 $1-\epsilon$ 的概率令 $\kappa(t) = 0$，否则从 N 中均匀采样 $\kappa(t) = n$。
    用户并行生成上报 $a_n(t) = \hat{\theta}_n(t) \sim \pi_n(\cdot \mid o_n(t))$，$\forall n \in N$。
    根据 $s(t)$ 与 $\hat{\boldsymbol{\theta}}(t) = \{\hat{\theta}_n(t)\}_{n\in N}$ 构造完整 UAV 观测 $o_0(t)$。
    if $\kappa(t) = 0$ **then**
      采样联合动作 $a_0(t) \sim \pi_0(\cdot \mid o_0(t))$ 并执行环境，获得 $\{\tau_n(t)\}_{n\in N}$、$E_0(t)$ 及下一观测。
      for all $n \in N$ **do**
        由式 (46) 计算 $p_n(t)$ 与 $r_n(t)$，存储用户转移 $(o_n(t), a_n(t), r_n(t), o_n(t+1))$ 至 $\mathcal{B}_n$。
      end for
      令 $r_0(t) = W(t)$，存储完整 UAV 转移 $(o_0(t), a_0(t), r_0(t), o_0(t+1))$ 至 $\mathcal{B}_0$。
    else
      令 $n = \kappa(t)$，构造 $o_0^{-n}(t)$，采样 $a_0^{-n}(t)$ 并执行反事实环境。
      令 $r_0^{-n}(t) = W^{-n}(a_0^{-n}(t), \boldsymbol{\theta}^{-n}(t))$，存储 $(o_0^{-n}(t), a_0^{-n}(t), r_0^{-n}(t), o_0^{-n}(t+1))$ 至 $\mathcal{B}_0$。
    end if
    for all $m \in \{0\} \cup N$ 且 $|\mathcal{B}_m| \geq B$ **do**
      从 $\mathcal{B}_m$ 采样小批量 $\mathcal{D}_m(t) = \{(o_m(\tau), a_m(\tau), r_m(\tau), o_m(\tau+1))\}$。
      由 $y_m(\tau) = r_m(\tau) + \gamma V_m(o_m(\tau+1))$ 更新 $\omega_m(t+1)$、$\psi_m(t+1)$、$\alpha_m(t+1)$ 与 $\hat{\omega}_m(t+1)$。
    end for
  end for
end for

5 仿真结果与分析（Simulation Results and Analysis）

说明：本节现有图表及数值来自原有算力分配规则，尚未依据本文修订后的联合计算决策重新生成，因此暂不能作为新模型性能的验证。需要确定 $\mathcal{F}$ 的离散取值并重新训练和评估各方法后，更新本节结果与结论。

5.1 仿真设置

本文在统一的离散 UAV 辅助 MEC 环境中训练并测试各比较方法，每个训练回合包含 10 个决策时隙，即 $T = 10$。在每个训练回合开始时独立生成用户类型。各时隙中的任务规模独立采样，从而刻画任务到达的随机性与用户间的资源竞争。

系统包含一架 UAV 和三名移动用户，用户数记为 $M = 3$。

用户的真实时延敏感系数 θ_n 从集合 $\{0.2, 0.5, 0.8\}$*code* 中独立均匀采样。各时隙中，任务规模 $D_n(t)$ 从集合 $\{100, 200, 300\}$ KB 中独立均匀采样。每比特所需 CPU 周期数设为 $\xi = 1000$，UAV 与本地设备的 CPU 频率分别设为 $F_{\text{uav}} = 0.1$ GHz 和 $f_{\text{loc}} = 1.5$ GHz。

物理场景设置为 $1\,\mathrm{km} \times 1\,\mathrm{km}$ 的服务区域，UAV 飞行高度和速度分别为 100 m 与 30 m/s。上行通信带宽为 0.2 MHz，用户发射功率为 10 dBm，噪声功率为 -80 dBm。LoS 概率参数取 $\mu_1 = 11.5$、$\mu_2 = 0.1$。LoS/NLoS 参考路径损耗分别取 -3 dB 和 -20 dB，路径损耗指数分别取 2 和 3.5。

各智能体均采用离散动作 SAC 进行训练，策略网络与双 Q 网络均采用两层全连接网络，并以修正线性单元（rectified linear unit, ReLU）作为激活函数。折扣因子设为 $\gamma = 0.99$，学习率设为 3×10^{-4}，初始温度参数为 0.2。UAV 与用户网络的隐藏层宽度分别为 128 和 64。UAV 的目标网络在每次参数更新后以 $\tau = 0.005$ 进行软更新，用户目标网络的更新间隔设为 10。各智能体经验回放池容量均设为 250000，小批量大小为 128。温度参数通过最大熵目标自适应调节，UAV 与用户的目标熵系数分别设为 -0.2 和 -0.005。所有实验采用随机种子 42。图 2给出了覆盖 2.5×10^6 个训练回合的回报演化过程。

5.2 对比方法与评价协议

即时 VCG 定价基线：该方法仍采用多智能体 SAC 学习用户上报策略与 UAV 卸载决策策略。在定价阶段，依据某用户参与所造成的当前时隙社会福利外部性确定其支付，即以该用户参与前后其余用户福利的变化衡量其支付成本。该基线保留联合学习与即时外部性定价过程，用于对比所提机制在支付设计上的改进。

无定价基线：该方法保留用户上报和 UAV 卸载决策过程，用户与 UAV 均通过 SAC 学习相应策略，但不设置任何支付规则。用户效用仅与任务完成时延相关，因而其上报与卸载决策不受经济支付的直接影响。该基线用于刻画不引入定价机制时系统的性能。

5.3 结果分析

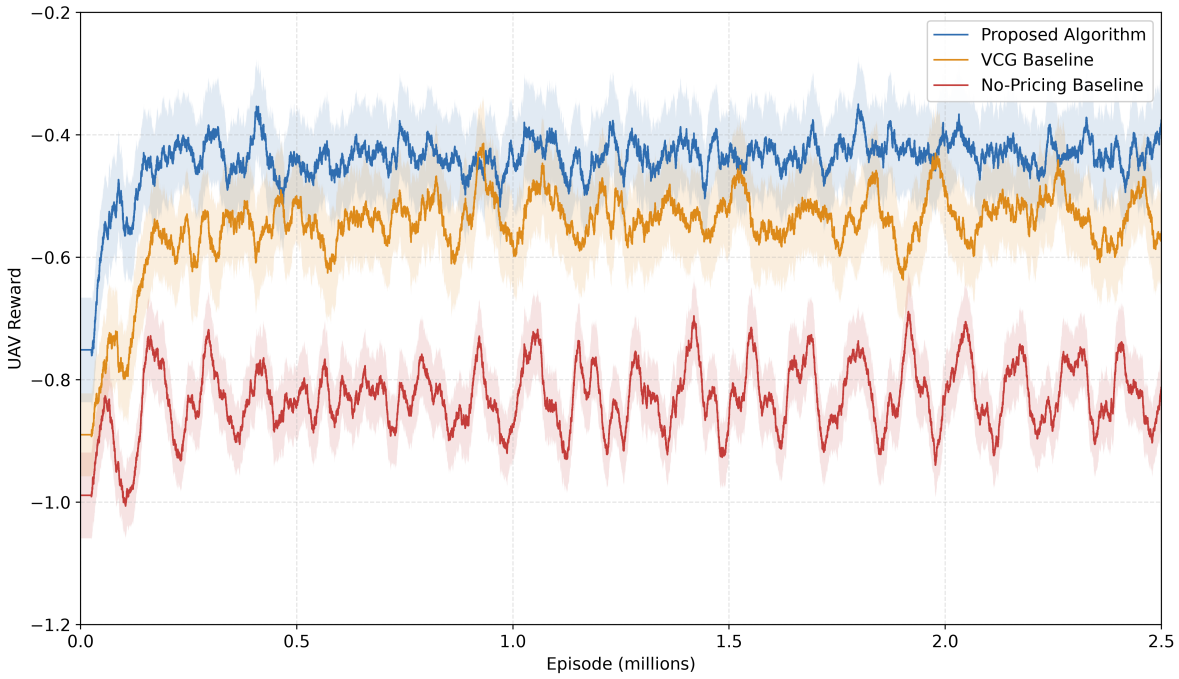


图 2: 所提方法与两类基线的 UAV 训练回报。

图 2给出了三种方法的 UAV 训练回报演化。所提方法在初始探索阶段后迅速达到稳定区间，且在后续训练中始终保持最高的平均回报。相比之下，即时 VCG 定价基线虽能利用即时外部性改善资源分配，但其反事实价值评估较为局部，稳定回报仍低于所提方法。无定价基线的回报最低且波动更为显著。这表明，支付机制不仅影响用户的上报动机，也能通过反事实价值定价改善 UAV 对用户类型的识别与卸载决策。

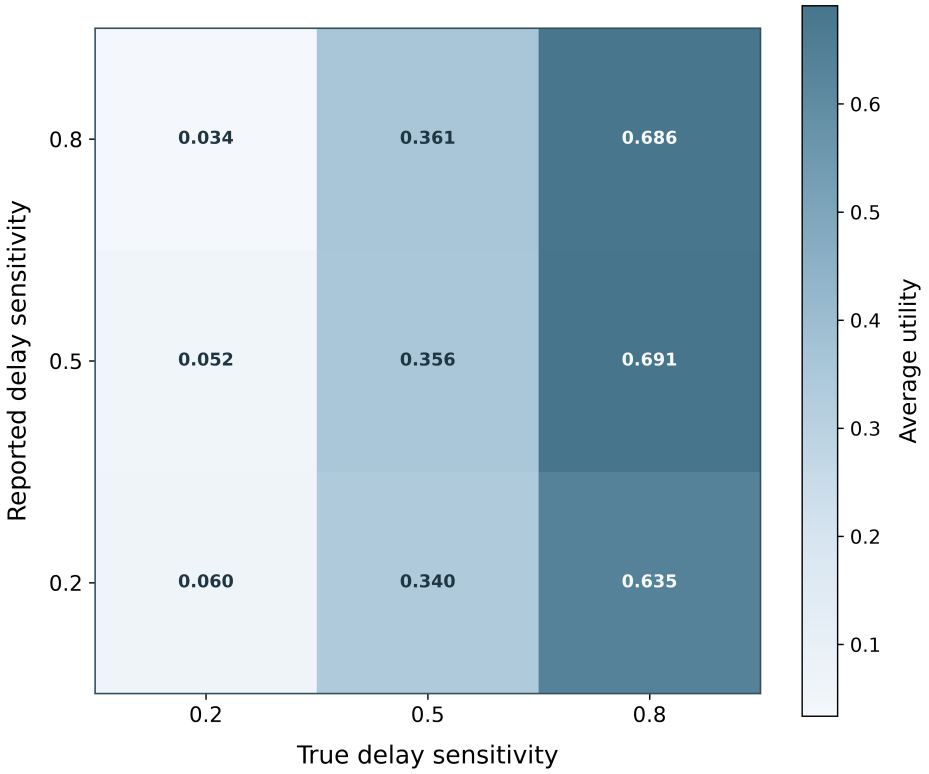
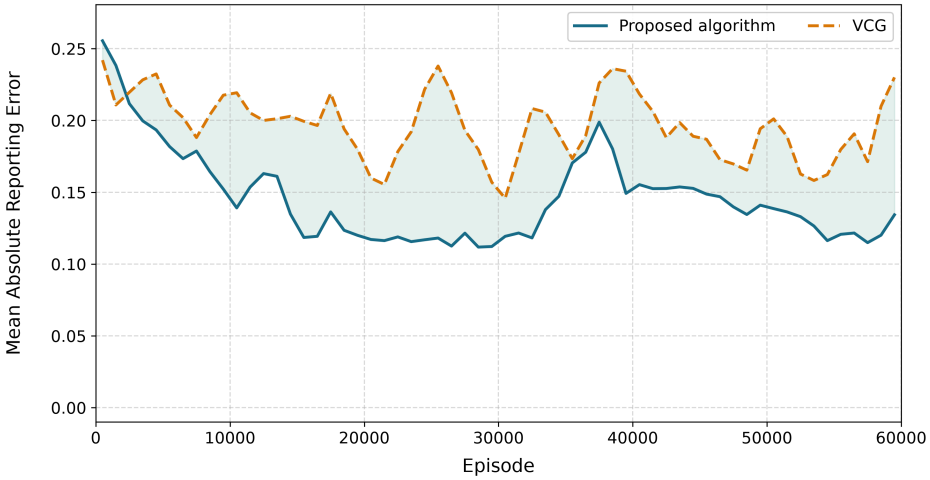
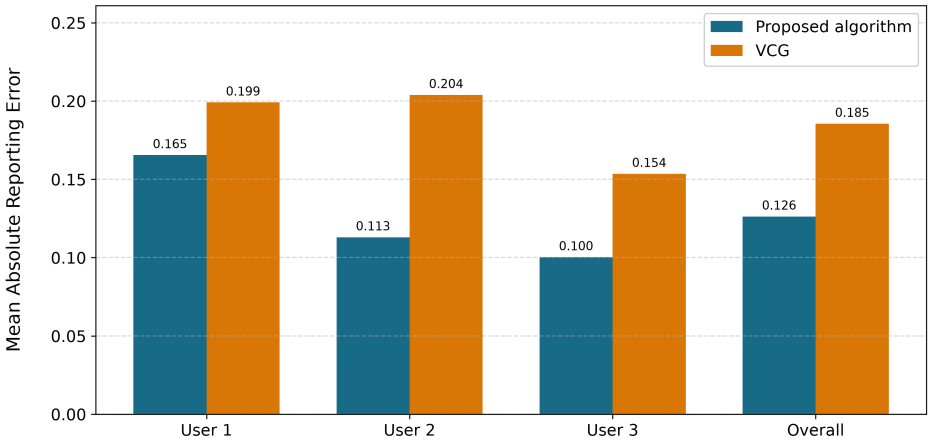


图 3: 不同真实时延敏感系数和上报敏感系数下的平均用户效用。

图 3刻画了真实类型与上报类型对平均用户效用的共同影响。总体而言，用户效用随真实时延敏感系数提高而增大，表明资源分配能够优先服务于对时延更敏感的任务。对于低敏感用户（$\theta = 0.2$），如实上报取得最高效用 0.060，而提高上报仅带来效用下降。对于中、高敏感用户，相邻上报水平之间的效用差异较小，最大偏离收益分别仅为 0.005 和 0.005。因此，所提机制能够显著抑制虚报动机，并呈现近似激励相容性。



(a) 平均绝对上报误差的训练演化。



(b) 各用户及总体平均绝对上报误差。

图 4: 所提方法与即时 VCG 定价基线下的用户上报偏差。

图 4(a) 给出了平均绝对上报误差随训练过程的变化。经过初始探索后，所提方法的误差稳定在较低区间，且整体低于即时 VCG 定价基线，表明反事实价值定价能够持续抑制策略性虚报。图 4(b) 进一步给出分用户比较：所提方法在三个用户上的平均绝对上报误差分别为 0.165、0.113 和 0.100，均低于即时 VCG 定价基线对应的 0.199、0.204 和 0.154。从总体指标看，所提方法将平均绝对上报误差由 0.185 降至 0.126，说明其能够更有效地将用户收益与真实类型对齐。

6 参考文献（References）

[1] Bo Shen, Qi Gu, and Gang Yang. Joint task offloading and UAVs deployment for UAV-assisted mobile edge computing. *Computer Networks*, 234:109943, 2023.

[2] Min Hui, Jian Chen, Long Yang, Lu Lv, Hai Jiang, and Naofal Al-Dhahir. UAV-assisted mobile edge computing: Optimal design of UAV altitude and task offloading. *IEEE Transactions on Wireless Communications*, 23(10):13633–13647, 2024.

[3] Tong Wang and Chuanchuan You. Distributed user association and computation offloading in UAV-assisted mobile edge computing systems. *IEEE Access*, 12:63548–63567, 2024.

[4] Shuyu Wang, Zhe Wang, Long Shi, Bin Li, and Jun Li. Opponent modeling based dynamic auction for UAV-assisted task offloading. In *2024 16th International Conference on Wireless Communications and Signal Processing (WCSP)*, pages 980–986, 2024.

[5] Ummy Habiba, Setareh Maghsudi, and Ekram Hossain. A repeated auction model for load-aware dynamic resource allocation in multi-access edge computing. *IEEE Transactions on Mobile Computing*, 23(7):7801–7817, 2024.

[6] Hualing Ren, Kai Liu, Guozhi Yan, Chunhui Liu, Yantao Li, Chuzhao Li, and Weiwei Wu. Truthful auction mechanisms for dependent task offloading in vehicular edge computing. *IEEE Transactions on Mobile Computing*, 23(12):14987–15002, 2024.

[7] Dirk Bergemann and Juuso Välimäki. The dynamic pivot mechanism. *Econometrica*, 78(2):771–789, 2010.

[8] Akram Al-Hourani, Sithamparanathan Kandeepan, and Abbas Jamalipour. Modeling air-to-ground path loss for low altitude platforms in urban environments. In *2014 IEEE Global Communications Conference*, pages 2898–2904. IEEE, 2014.

[9] Changsheng You, Kaibin Huang, Hyukjin Chae, and B.-H. Kim. Energy-efficient resource allocation for mobile-edge computation offloading. *IEEE Transactions on Wireless Communications*, 16(3):1397–1411, 2017.

[10] Yuyi Mao, Jun Zhang, and Khaled B. Letaief. Dynamic computation offloading for mobile-edge computing with energy harvesting devices. *IEEE Journal on Selected Areas in Communications*, 34(12):3590–3605, 2016.

[11] Edward H. Clarke. Multipart pricing of public goods. *Public Choice*, 11(1):17–33, 1971.

[12] Tuomas Haarnoja, Aurick Zhou, Pieter Abbeel, and Sergey Levine. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In *Proceedings of the 35th International Conference on Machine Learning*, volume 80 of *Proceedings of Machine Learning Research*, pages 1861–1870. PMLR, 2018.